PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ivan Araquistain Marquina**
Codirector[1]:	

La propuesta puede ser individual, aunque también se adapta a TFE grupal	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta (Máximo 20 palabras).

Pipeline para la predicción de caudal de ríos

Descripción del problema a abordar (Máximo 300 palabras).

Las crecidas de ríos son fenómenos naturales que pueden causar inundaciones y daños significativos en comunidades cercanas a los cuerpos de agua. Estos eventos pueden ser desencadenados por lluvias intensas, deshielos, tormentas tropicales o cualquier factor que aumente el caudal de un río. La detección temprana de crecidas de ríos es esencial para tomar medidas rápidas y proteger vidas y propiedades.

En este trabajo se propone el desarrollo de una solución de análisis y predicción con las siguientes características:

- Datos provenientes de diversas fuentes: APIs de servicios meteorológicos, sensores de nivel propios, APIs de sensores de nivel públicos.
- Capaz de entrenar modelos para predicción de nivel en diferentes intervalos temporales: por ejemplo, 1 hora, 4 horas, 8 horas, 24 horas.

Las tereas del alumno/alumnos se centrarán en el diseño de la arquitectura del software de captura y predicción, así como en el entrenamiento de modelos de IA. (Ver .PDF, TFE 2).

[1] Únicamente en el caso de doctorando y que no sea pdi de la universidad.



Figura 1. Sensor de nivel de agua IoT por ultrasonidos (estado del arte)

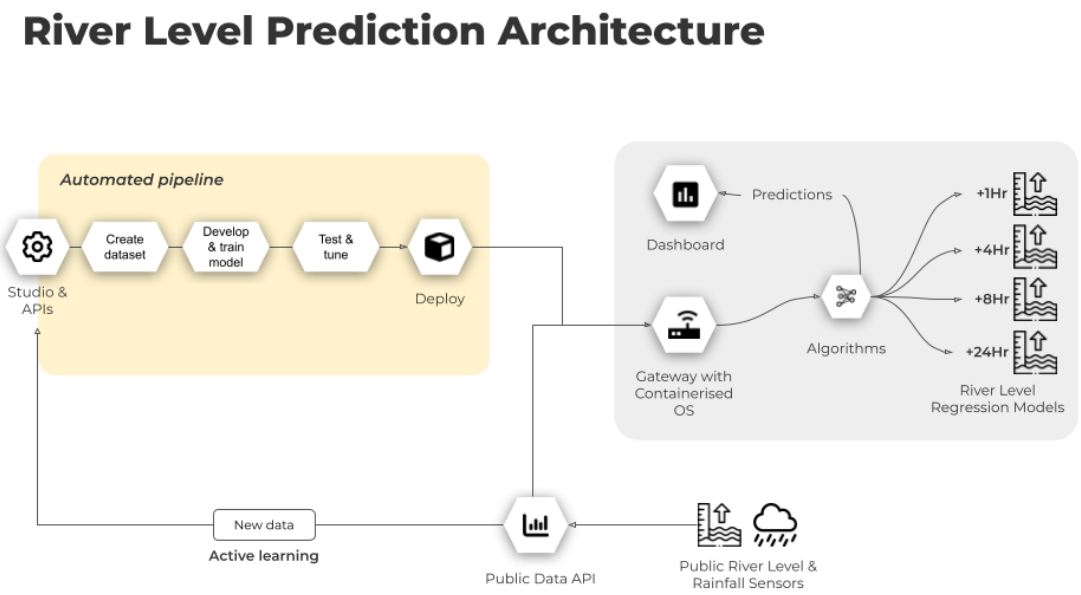


Figura 2. Diagrama de bloques de la arquitectura del sistema

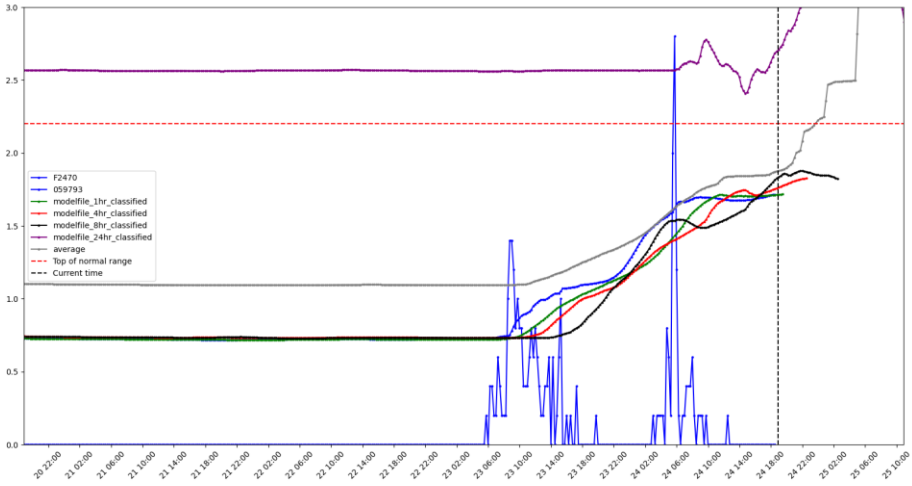


Figura 3. Desarrollo de modelos IA de predicción

Bibliografía:

- Edgeimpulse. (n.d.). GitHub - edgeimpulse/flood-monitoring-example-project: Transformation blocks & README to support a river level time series forecasting example project in Edge Impulse. GitHub. https://github.com/edgeimpulse/flood-monitoring-example-project/tree/main

- Ivan Arakistain, Diego Zamora, David Garcia-Sanchez, Alberto Armijo. LTO BATTERY USEFUL LIFE PREDICTION FOR ALWAYS ON EDGE AIoT BASED STRUCTURAL HEALTH MONITORING. The 26th European Conference on Power Electronics and Applications, GDR SEEDS France & EPE Association, Mar 2025, Paris, France. ⟨10.34746/epe2025-0264⟩.

Información adicional (opcional):

Contexto del problema (Máximo 100 palabras):	Desarrollo de un prototipo funcional. Inspiración: https://www.edgeimpulse.com/blog/building-an-advanced-flood-monitoring-system-with-edge-impulse/ https://github.com/edgeimpulse/flood-monitoring-example-project/tree/main
Conceptos que el alumno debe dominar (ítems)	• Desarrollo de un Data Lake para la captura y análisis de datos multifuente. • Programación en Python. • Interés por los modelos IA de regresión y predicción. Como redes convolucionales (CNN) para la extracción de patrones y modelos

	secuenciales como LSTM y Transformers para capturar dependencias temporales.
+ Información	La situación de partida del proyecto es que por otra parte se está trabajando en una solución IoT innovadora para la monitorización del nivel de agua de los ríos. En este proyecto se propone hacer uso de múltiples fuentes de datos (entre ellas los sensores de nivel propios).

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO, MÁSTER O DOCTORADO

Director de la propuesta:	**Sergio Mauricio Martinez Monterrubio**
Codirector[1]:	**Ruth Palmero Sánchez**
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Diseño e implementación de políticas de seguridad informática basadas en inteligencia artificial para la protección de infraestructuras críticas y datos sensibles

Descripción del problema a abordar

En un contexto de digitalización acelerada, las organizaciones públicas y privadas enfrentan un incremento en la complejidad y frecuencia de los ciberataques. Las políticas de seguridad informática tradicionales, centradas en la prevención estática, resultan insuficientes para responder a amenazas dinámicas, automatizadas y basadas en inteligencia artificial (IA).

El objetivo de esta propuesta es **analizar, diseñar y validar políticas de seguridad informática inteligentes**, capaces de adaptarse en tiempo real a contextos cambiantes mediante técnicas de aprendizaje automático, análisis de comportamiento de red y detección de anomalías.

El trabajo permitirá al estudiante:

- Estudiar marcos normativos y estándares internacionales de seguridad (ISO/IEC 27001, NIST, ENS).
- Diseñar modelos predictivos para la detección temprana de incidentes de seguridad.
- Desarrollar un prototipo de sistema de apoyo a la toma de decisiones en políticas de seguridad mediante IA.
- Evaluar la eficacia de dichas políticas en entornos simulados o casos de estudio reales.

Bibliografía recomendada:

- Stallings, W. (2023). *Computer Security: Principles and Practice*. Pearson.
- ISO/IEC 27001:2022. *Information Security Management Systems — Requirements*.
- NIST (2020). *Framework for Improving Critical Infrastructure Cybersecurity*.
- Russell, S. & Norvig, P. (2022). *Artificial Intelligence: A Modern Approach*. Pearson.
- Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press.
- Bishop, M. (2018). *Computer Security: Art and Science*. Addison-Wesley.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Información adicional (opcional):

Contexto del problema:	La propuesta puede desarrollarse en colaboración con un grupo de investigación universitario o una empresa del sector tecnológico interesada en la gestión de ciber-riesgos o en el desarrollo de soluciones inteligentes para seguridad informática. También podría vincularse con proyectos relacionados con **CuantaIA** y el **análisis de datos para la seguridad digital en observatorios globales**, integrando la dimensión de gobernanza de datos y cumplimiento de los ODS (Objetivos de Desarrollo Sostenible)
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	1. Fundamentos de **seguridad informática y ciberdefensa**. 2. Conocimientos de **machine learning** y **detección de anomalías**. 3. Manejo de **Python**, **TensorFlow/PyTorch**, y **herramientas SIEM/SOAR**. 4. Conocimiento básico de **normativas y estándares de seguridad** (ISO 27001, NIST, GDPR). 5. Capacidad analítica y de redacción de políticas o procedimientos técnicos.
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO, MÁSTER O DOCTORADO

Director de la propuesta:	**Sergio Mauricio Martinez Monterrubio**
Codirector[2]:	**Ruth Palmero Sánchez**
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Modelado y desarrollo de estrategias de seguridad para ciudades inteligentes basadas en inteligencia artificial y análisis de datos

Descripción del problema a abordar

Tipología o especialidad: Seguridad en sistemas inteligentes, protección de infraestructuras urbanas y análisis de riesgos tecnológicos en entornos urbanos.

Información adicional (opcional):

Contexto del problema:	Las **ciudades inteligentes (smart cities)** dependen de una infraestructura digital compleja que integra sensores, redes IoT, plataformas de datos y sistemas automatizados para la gestión de servicios públicos (transporte, energía, salud, medio ambiente, etc.). Sin embargo, esta interconexión también **aumenta la superficie de ataque** y **la vulnerabilidad frente a amenazas cibernéticas y físicas**, afectando potencialmente la privacidad ciudadana, la integridad de los datos y la continuidad de los servicios críticos. El propósito de esta propuesta es **investigar, diseñar y validar políticas, modelos y herramientas tecnológicas que incrementen la seguridad de las ciudades inteligentes**, mediante el uso de técnicas de **inteligencia artificial, análisis predictivo y gestión de ciber-riesgos urbanos**. El trabajo permitirá al estudiante: • Analizar los riesgos de ciberseguridad en infraestructuras urbanas inteligentes (IoT, transporte, energía, administración electrónica). • Aplicar técnicas de aprendizaje automático y detección de anomalías para la **prevención y respuesta ante incidentes**. • Diseñar **modelos de gobernanza y políticas públicas de seguridad digital** para entornos urbanos.

[2] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

	• Integrar los resultados en el marco de los **Objetivos de Desarrollo Sostenible (ODS)**, especialmente en los ODS 9 (industria e innovación) y 11 (ciudades sostenibles). **Bibliografía recomendada:** 1. Hashem, I. A. T., et al. (2016). *The role of big data in smart city applications: Challenges and opportunities.* Elsevier. 2. Zanella, A., et al. (2014). *Internet of Things for Smart Cities*. IEEE Internet of Things Journal. 3. ISO/IEC 30182:2017. *Smart city concept model — Guidance for establishing a model for data interoperability*. 4. NIST (2022). *Cybersecurity Framework for Smart Cities and IoT Systems*. 5. Alazab, M. (2020). *Cybersecurity in Smart Cities: Challenges and Solutions*. Springer. 6. Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	**Contexto del problema:** La propuesta puede desarrollarse en colaboración con proyectos de investigación en **gobernanza de datos urbanos** o con **empresas y administraciones públicas** que trabajen en la digitalización segura de servicios urbanos. También podría vincularse con el proyecto **CuantaIA**, en su dimensión de **observatorio global de datos abiertos**, para **monitorizar y evaluar la seguridad y sostenibilidad de ciudades inteligentes** utilizando inteligencia artificial y analítica de datos. **Conceptos / herramientas / técnicas que es recomendable que el alumno domine:** • Fundamentos de **ciberseguridad y privacidad en IoT y sistemas urbanos conectados**. • Conocimientos de **inteligencia artificial, machine learning y análisis predictivo**. • Programación en **Python** y uso de librerías como **Scikit-learn, TensorFlow o PyTorch**. • Manejo de herramientas para la **visualización y análisis de datos urbanos** (Tableau, Power BI, Grafana). • Comprensión de **normativas y estándares de seguridad en smart cities** (ISO 30182, NIST, ENS, GDPR). • Capacidad de integrar aspectos técnicos, sociales y éticos en el diseño de políticas públicas de seguridad.
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO, MÁSTER O DOCTORADO

Director de la propuesta:	**Sergio Mauricio Martinez Monterrubio**
Codirector[3]:	**Ruth Palmero Sánchez**
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Aplicación de técnicas de inteligencia artificial para la detección, predicción y mitigación de ciberamenazas en entornos digitales

Descripción del problema a abordar

Tipología o especialidad: Aplicación de técnicas de inteligencia artificial al análisis, detección y respuesta ante amenazas de seguridad informática.

La ciberseguridad moderna se enfrenta a amenazas cada vez más sofisticadas y automatizadas, como ataques de phishing avanzados, malware polimórfico, ransomware o intrusiones en redes corporativas. Estas amenazas evolucionan rápidamente, superando la capacidad de respuesta de los sistemas de defensa tradicionales basados en reglas o firmas estáticas.

La inteligencia artificial (IA) ofrece nuevas oportunidades para anticipar, detectar y mitigar ciberataques mediante el análisis automatizado de grandes volúmenes de datos, la detección de anomalías y la predicción de comportamientos maliciosos.

El objetivo de esta propuesta es desarrollar e implementar modelos de IA y aprendizaje automático aplicados a la ciberseguridad, explorando técnicas como:

- Machine learning supervisado y no supervisado para la detección de intrusiones.
- Deep learning y redes neuronales para la identificación de patrones de ataque.
- Procesamiento de lenguaje natural (NLP) para el análisis de texto en correos o mensajes sospechosos.
- IA explicable (XAI) para la interpretación de decisiones automáticas en entornos críticos de seguridad.

Bibliografía recomendada:

- Sommer, R., & Paxson, V. (2010). *Outside the Closed World: On Using Machine Learning for Network Intrusion Detection.* IEEE Symposium on Security and Privacy.

[3] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

- Buczak, A. L., & Guven, E. (2016). *A survey of data mining and machine learning methods for cyber security intrusion detection.* IEEE Communications Surveys & Tutorials.
- Alazab, M. (2021). *Artificial Intelligence for Cybersecurity: Techniques, Applications and Challenges.* Springer.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning.* MIT Press.
- Russell, S. & Norvig, P. (2022). *Artificial Intelligence: A Modern Approach.* Pearson.
- Bishop, M. (2018). *Computer Security: Art and Science.* Addison-Wesley.

Información adicional (opcional):

Contexto del problema:	La propuesta puede desarrollarse en el marco de proyectos de investigación o colaboración con centros especializados en ciberseguridad e inteligencia artificial, empresas tecnológicas, o en el contexto del observatorio global CuantaIA, para integrar la detección de ciberamenazas en sistemas de datos abiertos y plataformas inteligentes. Existe también la posibilidad de orientar el trabajo hacia la publicación de un artículo científico sobre IA aplicada a la ciberdefensa o detección de amenazas emergentes.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	1. Fundamentos de seguridad informática y ciberdefensa. 2. Conocimientos de machine learning, deep learning y detección de anomalías. 3. Programación en Python y manejo de librerías como Scikit-learn, TensorFlow, PyTorch y Keras. 4. Experiencia básica con datasets de ciberseguridad (CICIDS, NSL-KDD, UNSW-NB15, etc.). 5. Comprensión de marcos normativos (ISO/IEC 27001, NIST Cybersecurity Framework). 6. Habilidades de evaluación de rendimiento de modelos y análisis interpretativo de resultados (XAI, SHAP, LIME).
+ Información	

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**José Manuel Bernal de Lázaro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Evaluación de enfoques de aprendizaje por refuerzo para el control de sistemas ciberfísicos

Descripción del problema a abordar

Se estudian y comparan diferentes algoritmos de aprendizaje por refuerzo aplicados al control de sistemas ciberfísicos, considerando su capacidad para adaptarse a entornos dinámicos y complejos. El objetivo es analizar su desempeño en términos de estabilidad, eficiencia y robustez frente a perturbaciones o incertidumbre en el sistema.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Familiarizarse con los procesos físicos, y datos Conocimientos básicos de álgebra matricial Manejo de lenguajes de programación Python/Matlab
+ Información	

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ivón Oristela Benítez González**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Arquitectura basada en inteligencia artificial y analítica de datos para la optimización y mantenimiento predictivo en sistemas industriales 4.0

Descripción del problema a abordar

El presente trabajo propone el diseño de una arquitectura basada en inteligencia artificial y analítica de datos orientada a la optimización operativa y el mantenimiento predictivo en sistemas industriales 4.0. La solución integra la adquisición de datos mediante tecnologías IoT, su procesamiento y análisis para extraer conocimiento útil sobre el comportamiento de los activos industriales.

A través del uso de algoritmos de aprendizaje automático, la arquitectura permitirá identificar patrones, detectar anomalías y predecir fallos, facilitando la toma de decisiones en tiempo real. Este enfoque contribuye a mejorar la eficiencia, reducir tiempos de inactividad y aumentar la confiabilidad de los sistemas en entornos industriales inteligentes.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Fundamentos de Industria 4.0, IoT y arquitecturas de datos (adquisición, comunicación y procesamiento). Conocimientos de inteligencia artificial y machine learning para predicción y detección de anomalías. Conceptos de mantenimiento predictivo y confiabilidad (MTBF, MTTR, análisis de fallos). Manejo de Python y herramientas de analítica de datos (pandas, scikit-learn, visualización).
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Cristian Franco González**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Redes Neuronales Físicamente Informadas (Revisión Bibliográfica + Aplicación Libre)

Descripción del problema a abordar

En los últimos años, las redes neuronales físicamente informadas (Physics-Informed Neural Networks, PINNs) han emergido como una de las líneas más prometedoras dentro del campo del aprendizaje automático aplicado a problemas científicos. A diferencia de los enfoques puramente basados en datos, las PINNs incorporan de manera explícita ecuaciones diferenciales, leyes de conservación o restricciones físicas dentro del proceso de entrenamiento, integrando conocimiento previo del sistema en la función de pérdida del modelo. Esta aproximación permite abordar problemas gobernados por ecuaciones en derivadas parciales, incluso en escenarios con datos escasos o ruidosos.

El creciente interés por las PINNs ha dado lugar a una literatura extensa y diversa que abarca fundamentos teóricos, desarrollos metodológicos, variantes arquitectónicas y aplicaciones en múltiples disciplinas como dinámica de fluidos, mecánica de sólidos, electromagnetismo, física cuántica o biomedicina. Sin embargo, el campo presenta aún desafíos abiertos relevantes, como la estabilidad del entrenamiento, el balance entre términos de pérdida físicos y datos observacionales, la escalabilidad a problemas de alta dimensión y la comprensión teórica de su capacidad de generalización.

El objetivo de este trabajo consiste en realizar una revisión bibliográfica sistemática y crítica del estado del arte en redes neuronales físicamente informadas, analizando su formulación matemática, principales variantes (hard vs. soft constraints, enfoques basados en residuales, DeepONets, operator learning, etc.), ventajas y limitaciones. Se prestará especial atención a los aspectos teóricos relacionados con la convergencia, la expresividad y el comportamiento de optimización, así como a comparativas con métodos numéricos tradicionales.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

En primer lugar hemos de ofrecer una síntesis estructurada que permita clarificar el panorama actual del área, identificar líneas de investigación abiertas y evaluar el potencial real de las PINNs como herramienta de integración entre aprendizaje automático y modelización científica. Este trabajo proporcionará una base sólida para futuras aplicaciones específicas en contextos físicos o ingenieriles, además de contribuir a una comprensión más profunda del marco conceptual del aprendizaje automático guiado por principios físicos.

Además de la revisión sistemática, se plantea la implementación de una PINN para resolver un problema físico representativo (a concretar), incluyendo tanto formulación directa como, si es posible, un problema inverso. Se analizarán de forma crítica las limitaciones del enfoque, comparándolo con métodos numéricos tradicionales. La selección del problema y el alcance final se concretarán en la primera reunión, permitiendo adaptar el trabajo al perfil e intereses del estudiante.

Bibliografía de referencia:

- **Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). *Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*. Journal of Computational Physics, 378, 686–707. https://arxiv.org/abs/1711.10561**
- **Lu, L., Jin, P., Pang, G., Zhang, Z., & Karniadakis, G. E. (2021). *Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators*. Nature Machine Intelligence, 3, 218–229. https://arxiv.org/abs/2003.05512**
- **Ren, P., Rao, C., Liu, Y., Wang, J., & Sun, H. (2021). *PhyCRNet: Physics-informed Convolutional-Recurrent Network for Solving Spatiotemporal PDEs*. arXiv:2106.14103.**

Información adicional (opcional):

Contexto del problema:	La motivación de este TFE surge de una colaboración entre Paul A. Pintea y Cristian Franco ambos estudiando aplicaciones de las PINNS en diferentes ámbitos.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Conocer el funcionamiento de las redes neuronales clásicas, para poder adentrarse en el estudio de las PINNS (Physical Informed Neural Networks) así como conocimientos fundamentales en ecuaciones diferenciales. Nociones de Python, pandas y algún framework de desarrollo de Deep Learning, ya sea keras, tensorflow o pytorch.

+ Información	Bajo demanda a Cristian Franco González.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Cristian Franco González**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Redes Neuronales Físicamente Informadas para detectar anillos de Einstein

Descripción del problema a abordar

El uso de *Physics-Informed Neural Networks* (PINNs) para la detección de anillos de Einstein constituye una línea de investigación emergente que combina aprendizaje automático con conocimiento físico explícito. Los anillos de Einstein son una manifestación del fenómeno de lente gravitacional fuerte, cuya identificación automática en grandes volúmenes de datos sigue siendo un reto relevante. La misión **Euclid** de la ESA está generando imágenes de alta resolución a gran escala con el objetivo de estudiar la energía oscura y la estructura del universo, lo que hace especialmente pertinente el desarrollo de métodos automatizados avanzados (Euclid Collaboration, 2022–2024).

El planteamiento del TFE consiste en diseñar una PINN que incorpore en su función de pérdida tanto la fidelidad a los datos observacionales como las ecuaciones físicas del fenómeno de lente gravitacional, en particular la ecuación de lente. Este enfoque permite integrar conocimiento previo en el modelo, reduciendo la dependencia de grandes conjuntos de datos etiquetados, a diferencia de métodos puramente supervisados basados en CNNs (Raissi et al., 2019). Además, podría combinarse el uso de datos simulados y reales de Euclid para evaluar el comportamiento del modelo en distintos escenarios.

Desde el punto de vista metodológico, el trabajo debería centrarse en la correcta formulación de la pérdida física, la robustez frente a ruido y artefactos observacionales, y la comparación con enfoques existentes basados en aprendizaje profundo, que han demostrado gran eficacia en la detección de lentes gravitacionales (Hezaveh et al., 2017). Asimismo, resulta relevante analizar si las PINNs aportan ventajas en términos de interpretabilidad, permitiendo no solo detectar anillos de Einstein sino también inferir propiedades físicas de la lente.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

No obstante, es importante señalar que las PINNs presentan limitaciones, como dificultades de entrenamiento en problemas de alta dimensionalidad y un coste computacional elevado. Además, no está garantizado que superen a las CNNs en tareas puramente visuales. Por ello, el TFE debe incluir un análisis crítico que determine en qué condiciones el enfoque físicamente informado aporta ventajas reales frente a métodos existentes (Nightingale et al., línea de trabajos recientes en modelado de lentes).

Bibliografía de referencia:

- **Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). *Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*. Journal of Computational Physics.**
- **Euclid Collaboration (2022–2024). *Euclid mission overview and early data releases*. ESA.**
- **Hezaveh, Y. D. et al. (2017). *Fast automated analysis of strong gravitational lenses with convolutional neural networks*. Nature.**
- **Koopman, L. et al. / Nightingale, J. (línea de trabajos recientes en modelado de lentes gravitacionales con ML y métodos híbridos).**

Información adicional (opcional):

Contexto del problema:	La motivación de este TFE surge de una colaboración entre Paul A. Pintea y Cristian Franco ambos estudiando aplicaciones de las PINNS en diferentes ámbitos. Este trabajo se podría publicar en alguna conferencia de la ESA (Agencia Espacial Europea) y podría ser la semilla de una investigación financiada para algún doctorado.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Conocer el funcionamiento de las redes neuronales clásicas, para poder adentrarse en el estudio de las PINNS (Physical Informed Neural Networks) así como conocimientos fundamentales en ecuaciones diferenciales. Nociones de Python, pandas y algún framework de desarrollo de Deep Learning, ya sea keras, tensorflow o pytorch.
+ Información	Bajo demanda a Cristian Franco González.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Igor Santos-Grueiro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Persistencia de comportamiento privilegiado tras cambios de permisos o memoria en asistentes basados en modelos de lenguaje

Descripción del problema a abordar

La incorporación de memoria persistente y aprendizaje a partir de experiencias previas está convirtiéndose en un componente central de los agentes LLM. Sin embargo, esa misma capacidad introduce un problema de seguridad nuevo: que el sistema siga actuando con conocimiento, planes o sesgos derivados de un estado anterior que ya no debería ser válido. La literatura reciente ya ha mostrado varias formas de compromiso persistente de la memoria del agente, incluyendo ataques de memory injection, memory poisoning, control de flujo inducido por memoria y compromisos duraderos de agentes autoevolutivos. En conjunto, estos trabajos sugieren que la memoria no es un mero componente auxiliar, sino una nueva superficie de ataque y de persistencia indebida del comportamiento.

Al mismo tiempo, encuestas recientes sobre seguridad de agentes y documentos regulatorios sobre agentic AI subrayan que la gestión de autoridad, trazabilidad, gobernanza de memoria y dependencia de contexto son cuestiones aún abiertas. No obstante, sigue faltando una caracterización experimental pequeña y clara de un caso muy concreto y relevante: qué ocurre cuando un asistente pierde permisos, cambia de rol o deja de poder acceder a una fuente, pero conserva internamente planes, inferencias o patrones construidos antes de esa revocación.

El objetivo de este TFM es estudiar, en un entorno acotado y reproducible, si un asistente con memoria sigue mostrando un comportamiento operativamente privilegiado después de que cambien sus permisos o se invalide parte de su contexto previo. El interés no está en resolver toda la gobernanza de memoria, sino en demostrar el fenómeno y medirlo con precisión.

Para ello, el alumno construirá un entorno experimental sencillo con usuarios, roles, recursos accesibles, políticas de acceso y un mecanismo básico de memoria o recuperación. A continuación, definirá escenarios de cambio de autoridad: revocación de permisos, cambio de rol, invalidación de una fuente previamente consultada o limpieza parcial de memoria. Sobre esos escenarios, medirá si el agente continúa generando respuestas, planes o acciones apoyadas en estado previo que ya no debería

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

considerarse operativo. El trabajo también podrá comparar mitigaciones sencillas, como revalidación obligatoria, invalidación de planes previos, reseteo selectivo de memoria o trazabilidad de procedencia.

La base científica es suficientemente sólida como para justificar el tema, pero todavía suficientemente abierta como para que un TFM aporte algo original. El estado del arte ha demostrado ataques persistentes sobre memoria; lo que aquí se propone es una versión más acotada, más medible y más alineada con semántica de autorización y validez operativa. Precisamente por eso tiene potencial: no exige construir un framework enorme, pero sí puede producir evidencia experimental útil para una línea mayor sobre revocación, memoria y consistencia semántica en agentes.

Bibliografía recomendada:

Dong, X. et al. *A Practical Memory Injection Attack against LLM Agents (MINJA)*, 2025.

Memory Control Flow Attacks on LLM Agents, 2026.

Zombie Agents: Persistent Control of Self-Evolving LLM Agents, 2026.

MemoryGraft: Persistent Compromise of LLM Agents via Poisoned Experience Retrieval, 2025.

Governing Evolving Memory in LLM Agents, 2026.

He, F. et al. *The Emerged Security and Privacy of LLM Agent: A Survey*, ACM Computing Surveys, 2025.

Información adicional (opcional):

Contexto del problema:	Exige definir con precisión el experimento y diferenciar correctamente entre memoria útil, persistencia legítima del contexto y persistencia indebida del comportamiento

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Programación web o backend OWASP Top 10 y desarrollo seguro Análisis estático y gestión de dependencias Uso de asistentes de código y prompting reproducible Diseño experimental comparativo Documentación y clasificación de fallos
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Carlos Rubert Escuder**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Ajuste fino eficiente y comparación de modelos de lenguaje compactos para generar variantes DUA-A de materiales de ESO: simplificación, apoyos textuales y evaluación reproducible

Descripción del problema a abordar

El TFM se centra en entrenar y comparar varios modelos compactos (pocos parámetros) para transformar un texto curricular de ESO en un "paquete de variantes" alineado con DUA-A, limitando el alcance a transformaciones que un modelo pequeño puede realizar con calidad y control:

1. Variantes por grado de complejidad: versión estándar y una o dos versiones de lenguaje claro/lectura fácil (según restricciones definidas).

2. Variantes por formato (solo texto, sin multimodalidad): esquema jerárquico, glosario mínimo de términos clave y preguntas de comprobación con respuestas breves.

El objetivo no es capturar toda la casuística NESE ni diagnosticar perfiles; es operacionalizar un subconjunto del DUA-A, medible y reproducible, que reduzca carga cognitiva y mejore acceso al contenido mediante estructura, claridad y apoyos.

Delimitación y objetivos académicos:

1. Definir formalmente la tarea "DUA-A textual" (alcance mínimo viable).
   - Para cada texto fuente, generar exactamente:
     a) versión estándar (sin cambios o con mínimos),
     b) versión simplificada (lenguaje claro),
     c) versión de lectura fácil (opcional si se define como tercer nivel),
     d) glosario (5–10 términos),
     e) esquema (6–12 nodos),
     f) 5–8 preguntas con respuesta breve.
   - Fijar restricciones objetivas: longitud máxima, longitud media de frase, estructura (párrafos cortos), obligatoriedad de términos curriculares.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

2. Construir un corpus mínimo y controlado, con ampliación semiautomática.
   En lugar de "crear un gran corpus NESE", se usa un enfoque de tres capas:
   - Capa A (semilla manual): 50–120 textos fuente cortos (150–400 palabras) de 2–3 temas de ESO; para cada texto, solo se anotan manualmente 2 salidas: versión simplificada y glosario (la parte más valiosa).
   - Capa B (generación asistida): el propio modelo base produce borradores del resto de formatos (esquema y preguntas) siguiendo plantillas; el alumnado revisa una muestra pequeña (por ejemplo, 10–20%) para corregir errores típicos y definir reglas.
   - Capa C (autofiltrado): se aplica filtrado automático (formato, longitud, cobertura de términos clave) para aceptar/rechazar ejemplos generados.

3. Seleccionar y comparar modelos compactos de forma realista (2–3 candidatos).
   - Criterios: desempeño en español, licencia, tamaño, estabilidad de generación, viabilidad de ajuste fino con recursos disponibles.
   - Comparación en tres condiciones:
     a) modelo sin especialización (plantillas),
     b) modelo con ajuste fino eficiente (adaptadores),
     c) modelo con ajuste fino + restricciones más estrictas (para medir sensibilidad).

4. Implementar el ajuste fino eficiente con un protocolo replicable.
   - Ajuste fino con adaptadores (por ejemplo, LoRA) y configuración común entre modelos.
   - Registro exhaustivo de configuración, semillas, particiones y métricas, de manera que la comparación sea defendible.

5. Evaluación mixta acotada (automática + humana mínima).
   - Automática (para todo el test congelado):
     a) cumplimiento de restricciones (longitud, estructura, presencia de glosario, número de preguntas),
     b) preservación de términos obligatorios,
     c) similitud semántica con el texto fuente (como señal de pérdida de contenido).
   - Humana (muestra pequeña, pero bien definida): 30–60 casos evaluados con una rúbrica breve (claridad, fidelidad, adecuación a ESO, utilidad del esquema/preguntas).
   - Informe de errores con categorías y ejemplos.

6. Entregar un paquete reproducible y reutilizable.
   - Código, configuración, conjunto de prueba congelado, informes de resultados, y "fichas de uso" (qué hace bien, qué hace mal, cuándo requiere revisión docente).

Información adicional (opcional):

Contexto del problema:	El DUA-A insiste en que el acceso a la información es un requisito previo para el aprendizaje, y propone, entre otras medidas, ofrecer materiales con distintos grados de complejidad y aplicar criterios de accesibilidad textual (por ejemplo, lectura fácil) para facilitar la comprensión. Además, dentro de los principios de diseño universal, se explicita que conviene presentar el material en diversos formatos y con diferentes niveles de complejidad (incluyendo ejemplos como lectura fácil y audiolibro), así como incorporar apoyos como resúmenes, esquemas, organizadores y refuerzo de vocabulario. En el contexto de TFM del máster, esto se traduce en un problema de procesamiento del lenguaje natural con control de salida y evaluación rigurosa (modelos de PLN), diseño e implementación de sistemas de aprendizaje automático y análisis del rendimiento y estimación y evaluación del rendimiento según datos y contexto de ejecución. También exige un diseño experimental que controle errores y documente limitaciones
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	1. Procesamiento del Lenguaje Natural y generación controlada • Reescritura monolingüe (simplificación) y control de complejidad (longitud de frase, densidad terminológica, estructura). • Generación estructurada de salidas (esquemas y preguntas) con plantillas de formato fijo para reducir variabilidad y errores. 2. Ajuste fino eficiente y comparación de modelos compactos • Ajuste fino con técnicas de bajo coste (por ejemplo, adaptación de bajo rango) para modelos de pocos parámetros. • Comparación entre 2–3 modelos compactos (en español o multilingües con buen rendimiento en español), manteniendo idénticas condiciones de entrenamiento y evaluación. 3. Operacionalización de DUA-A en tareas medibles • "Diversos formatos" como conjunto de salidas textuales diferenciadas (explicación breve, esquema, glosario, preguntas). • "Distintos grados de complejidad" como dos o tres niveles de reescritura (estándar, simplificado, lectura fácil/lenguaje claro), evitando exceso de información y mejorando organización. • "Apoyos" como refuerzo de vocabulario, organizadores y resúmenes, tal como se recomienda en el principio de flexibilidad. 4. Evaluación reproducible (automática y humana) • Métricas automáticas: validez de formato (si procede), longitud media de frase, cobertura de términos clave, y métricas de similitud semántica para detectar pérdidas de contenido. • Evaluación humana con rúbrica breve: fidelidad conceptual, claridad, adecuación a ESO, y ausencia de "ruido" o añadidos

	irrelevantes, en línea con el decálogo de acceso a la información. • Diseño experimental con control de errores y análisis de limitaciones.
+ Información	Bibliografía inicial (orientativa) • Hu, E. J., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. • Dettmers, T., et al. (2023). QLoRA: Efficient Finetuning of Quantized Large Language Models. • Xu, W., et al. (2016). Optimizing Statistical Machine Translation for Text Simplification (métrica SARI). • Zhang, T., et al. (2019). BERTScore: Evaluating Text Generation with BERT. • Agustí Almela, F. J. et al. (2023). DUA-A: Diseño Universal y Aprendizaje Accesible (2.ª edición). • Revisiones de simplificación de texto (text simplification) centradas en evaluación y diseño de datos, para fundamentar el marco de calidad.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Igor Santos-Grueiro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Análisis empírico de riesgos de seguridad y cadena de suministro en código generado por asistentes de inteligencia artificial

Descripción del problema a abordar

La adopción de asistentes de programación basados en IA está acelerando la producción de software, pero también está creando una nueva vía de introducción de vulnerabilidades. La literatura reciente ya ha demostrado de forma empírica que los modelos de generación de código pueden producir paquetes inexistentes o alucinados a gran escala, y que este fenómeno no es anecdótico ni se limita a un único lenguaje o modelo. Un estudio amplio sobre 16 modelos y cientos de miles de muestras mostró que las package hallucinations constituyen un problema sistemático, con implicaciones claras para la seguridad de la cadena de suministro y para ataques como dependency confusion o instalación de paquetes maliciosos con nombres plausibles.

Más allá de las dependencias, estudios recientes también han analizado las alucinaciones en código generado y han propuesto taxonomías de fallos que afectan tanto a corrección funcional como a seguridad. Paralelamente, datos operativos del ecosistema muestran que la expansión del desarrollo asistido por IA está asociándose a un aumento de exposición de secretos y credenciales en repositorios, lo que refuerza la relevancia práctica del problema.

El objetivo de este TFM es realizar un estudio empírico, controlado y comparativo sobre los riesgos de seguridad presentes en código generado por asistentes de IA ante tareas realistas de desarrollo. La contribución no se planteará como una comparación superficial de "qué modelo programa mejor", sino como una caracterización de **qué clases de errores de seguridad** y **qué riesgos de cadena de suministro** aparecen, en qué condiciones y con qué frecuencia.

El trabajo partirá de un conjunto de prompts representativos de desarrollo web y backend, incluyendo autenticación, gestión de sesiones, APIs REST, subida de ficheros, integración con JWT, validación de entrada y uso de bibliotecas externas. Para cada tarea, el alumno generará implementaciones con varios asistentes o modelos y evaluará el resultado mediante una combinación de revisión manual, análisis estático, comprobación de dependencias, pruebas funcionales simples y contraste con buenas prácticas de seguridad. La clasificación de resultados distinguirá, como mínimo, entre errores de

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

autenticación/autorización, validación insuficiente, exposición de secretos, configuración insegura, uso de componentes desactualizados y package hallucinations.

La justificación científica es clara: el estado del arte ya muestra que el problema existe, pero sigue habiendo margen para estudios más aplicados, focalizados en escenarios de desarrollo realistas y con una taxonomía orientada específicamente a seguridad práctica. En un TFM, ese nivel de acotación es ideal porque permite obtener un conjunto de resultados sólidos sin necesidad de una infraestructura compleja. Además, el trabajo puede producir un corpus de prompts, código y etiquetas reutilizable para investigación posterior.

Bibliografía recomendada:

Spracklen, J. et al. *We Have a Package for You! A Comprehensive Analysis of Package Hallucinations by Code Generating LLMs*, USENIX Security 2025.

Exploring Hallucinations in LLM-Generated Code, 2024/2026 version disponible en arXiv.

Zhang, Y. et al. *Cutting the Root of Hallucination: Structural Trimming for Vulnerability Mitigation in Code LLMs*, COLM 2025.

OWASP Foundation. Guías OWASP Top 10 y prácticas de secure coding.

Información adicional (opcional):

Contexto del problema:	Este TFM se sitúa en la intersección entre ciberseguridad, ingeniería del software y modelos generativos. Es especialmente recomendable para alumnos con perfil aplicado, porque el problema es muy actual, fácilmente demostrable experimentalmente y con transferencia inmediata a entornos corporativos. Bien ejecutado, puede dejar un pequeño benchmark y una taxonomía útil para trabajos posteriores sobre copilotos de programación o seguridad de supply chain asistida por IA.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Programación web o backend OWASP Top 10 y desarrollo seguro Análisis estático y gestión de dependencias Uso de asistentes de código y prompting reproducible Diseño experimental comparativo Documentación y clasificación de fallos

+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Alain Gil Del Val**
Codirector[1]:	

La propuesta se adapta a TFE grupal	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta (Máximo 20 palabras).

Estrategia inteligente para la detección de la calidad de la rosca basado en datos reducidos

Descripción del problema a abordar (Máximo 300 palabras).

El objetivo es desarrollar una estrategia inteligente basada en datos reducidos que sea capaz de detectar la calidad de la rosca mecanizada en un proceso de fabricación por arranque de viruta a través de imágenes que se han obtenido a partir de técnicas de visión bidimensional (BLMD).

Bibliografía:

https://doi.org/10.1016/j.proeng.2015.12.469

https://doi.org/10.1007/s00170-013-5078-7

https://doi.org/10.3390/jmmp4010009

https://doi.org/10.3390/met11040537

Información adicional (opcional):

[1] Únicamente en el caso de doctorando y que no sea pdi de la universidad.

Contexto del problema (Máximo 100 palabras):	Posibilidad de desarrollar un artículo científico si los resultados son razonablemente buenos.
Conceptos que el alumno debe dominar (ítems)	Python
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Igor Santos-Grueiro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Detección y caracterización de fallos temporales en agentes basados en modelos de lenguaje a partir de trazas de ejecución

Descripción del problema a abordar

Los agentes basados en modelos de lenguaje ya no se limitan a producir texto: observan entornos, planifican, invocan herramientas y ejecutan acciones con efecto sobre sistemas externos. Ese salto convierte problemas clásicos de sistemas y seguridad —como TOCTOU, dependencia de estado obsoleto, reordenamiento incorrecto de pasos o reintentos no idempotentes— en un problema nuevo dentro de la seguridad de agentes. La literatura reciente ya ha empezado a señalar que los agentes LLM sufren vulnerabilidades específicas ligadas al desfase entre observación y acción, y que las defensas pensadas para interacciones simples no bastan cuando la ejecución se extiende en el tiempo o depende de varias llamadas a herramientas.

En paralelo, trabajos recientes muestran que los agentes presentan carencias en el manejo explícito del tiempo y que la percepción temporal en interacciones multi-turn todavía es frágil. Eso refuerza la hipótesis de que una parte relevante de los fallos inseguros no proviene solo de razonamiento "incorrecto", sino de una gestión deficiente de validez temporal, orden de ejecución y consistencia entre pasos.

El objetivo de este TFM es diseñar y evaluar un marco experimental pequeño pero reproducible para detectar este tipo de fallos a partir de trazas estructuradas de ejecución. El trabajo no pretende resolver toda la seguridad temporal de agentes, sino construir una base empírica: un conjunto de escenarios, un esquema de logging, una taxonomía de fallos y un detector inicial capaz de distinguir entre fallos temporales y no temporales con utilidad analítica real.

Las fases del trabajo incluirán, en primer lugar, el diseño de un banco de tareas reproducibles en el que un agente deba observar, decidir y actuar sobre un entorno controlado. Esas tareas incorporarán casos como uso de datos caducados, cambios de estado entre la comprobación y la ejecución, duplicación por retry, orden incorrecto de operaciones o dependencia de resultados ya invalidados. En segundo lugar, se definirá un formato de traza estructurada que recoja observaciones, planes, llamadas a herramientas, respuestas del entorno y decisión final. En tercer lugar, se construirá una taxonomía de fallos que permita clasificar ejecuciones como temporales, no temporales, mixtas o ambiguas. Finalmente, se

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

implementará un detector inicial —basado en reglas, heurísticas o clasificación ligera— y se evaluará frente a anotación manual.

Desde el punto de vista científico, la propuesta se apoya en un hueco real del estado del arte: ya existen trabajos sobre TOCTOU en agentes y sobre ataques de largo horizonte, pero sigue habiendo poco trabajo centrado específicamente en **detección automática basada en trazas** y en **separar causa temporal de otras clases de fallo** dentro de ejecuciones agentic.

Bibliografía recomendada:

Lilienthal, D. et al. *Mind the Gap: Time-of-Check to Time-of-Use Vulnerabilities in LLM-Enabled Agents*, 2025.

He, F. et al. *The Emerged Security and Privacy of LLM Agent: A Survey*, ACM Computing Surveys, 2025.

Información adicional (opcional):

Contexto del problema:	El interés de esta propuesta está en tender un puente entre conceptos clásicos de seguridad de sistemas y el comportamiento emergente de agentes LLM. Es un TFM realista porque puede acotarse a un entorno pequeño, no exige infraestructura costosa y genera artefactos reutilizables: casos, trazas, anotaciones y detector baseline. Además, ofrece potencial de continuidad hacia líneas más amplias sobre integridad temporal, consistencia operativa y auditoría de agentes.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Python y experimentación reproducible Modelos de lenguaje y agentes con tool-use Captura y análisis de logs o trazas Diseño experimental y evaluación de clasificación Conceptos de TOCTOU, atomicidad e idempotencia Visualización y análisis básico de resultados

+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Cristian Franco González**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Redes Neuronales Físicamente Informadas en sistemas biológicos

Descripción del problema a abordar

El presente trabajo propone estudiar la aplicación de *Physics-Informed Neural Networks* (PINNs) al modelado de sistemas biológicos dinámicos, como la expresión génica, redes regulatorias o modelos epidemiológicos. A diferencia de los enfoques puramente basados en datos, las PINNs permiten incorporar de forma explícita ecuaciones diferenciales que describen los procesos subyacentes, integrando conocimiento mecanístico con aprendizaje automático (Raissi et al., 2019). Este enfoque resulta especialmente relevante en biología, donde los datos suelen ser limitados, ruidosos o incompletos, pero existen modelos teóricos bien establecidos.

El objetivo principal será formular problemas biológicos como sistemas de ecuaciones diferenciales (ordinarias o en derivadas parciales) e implementar una PINN capaz de aprender soluciones consistentes con los datos observados y las restricciones físicas del sistema. En particular, se analizará la capacidad del modelo para inferir parámetros ocultos o reconstruir dinámicas no observadas, un aspecto clave en biología de sistemas y farmacocinética (Karniadakis et al., 2021). Asimismo, se evaluará la robustez frente a ruido y la estabilidad del entrenamiento, aspectos conocidos como limitaciones prácticas de las PINNs.

De forma complementaria, se podrá realizar una validación experimental mediante simulaciones de sistemas biológicos sencillos, comparando el rendimiento de las PINNs con métodos clásicos de ajuste de parámetros o integración numérica. Este análisis permitirá identificar en qué condiciones las PINNs ofrecen ventajas reales, tanto en términos de precisión como de interpretabilidad, frente a modelos tradicionales (Rackauckas et al., 2020).

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

En conjunto, el trabajo pretende contribuir a la comprensión del potencial de los enfoques físicamente informados en biología computacional, en línea con la creciente literatura en *scientific machine learning*, que busca integrar modelos mecanísticos y técnicas de aprendizaje automático en dominios científicos complejos (Karniadakis et al., 2021).

Referencias

- Raissi, M., Perdikaris, P., & Karniadakis, G. (2019). *Physics-informed neural networks*. Journal of Computational Physics.
- Karniadakis, G. E., et al. (2021). *Physics-informed machine learning*. Nature Reviews Physics.
- Rackauckas, C., et al. (2020). *Universal differential equations*. arXiv.

Información adicional (opcional):

Contexto del problema:	La motivación de este TFE surge de una colaboración entre Paul A. Pintea y Cristian Franco ambos estudiando aplicaciones de las PINNS en diferentes ámbitos.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Conocer el funcionamiento de las redes neuronales clásicas, para poder adentrarse en el estudio de las PINNS (Physical Informed Neural Networks) así como conocimientos fundamentales en ecuaciones diferenciales. Nociones de Python, pandas y algún framework de desarrollo de Deep Learning, ya sea keras, tensorflow o pytorch.
+ Información	Bajo demanda a Cristian Franco González.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Elsa Fernández Gómez de Segura**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Detección precoz de patologías oncológicas mediante Deep Learning y Visión Artificial

Descripción del problema a abordar

En la parte final de este bloque se recomienda poner bibliografía que podría leer el alumno para entender mejor la propuesta.

La interpretación de imágenes médicas (CT, MRI, Rayos X) es una tarea crítica que depende de la experiencia del radiólogo y está sujeta a la fatiga y la saturación del sistema sanitario. El problema central es el "cuello de botella" en el triaje oncológico, donde el retraso en el diagnóstico reduce drásticamente las tasas de supervivencia.

Este proyecto busca desarrollar y validar un sistema de apoyo a la decisión clínica (CDSS) basado en redes neuronales profundas. El alumno deberá abordar el pre-procesamiento de datos en formato **DICOM**, la implementación de arquitecturas de vanguardia (como **Vision Transformers o CNNs**) y la evaluación de métricas de sensibilidad y especificidad para asegurar que el modelo sea una herramienta fiable para reducir los falsos negativos en la detección de tumores.

Bibliografía recomendada:

- *Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning*. MIT Press.
- *Hosny, A., et al. (2018). Artificial intelligence in radiology*. Nature Reviews Cancer.
- *Zhou, S. K., et al. (2021). A review of deep learning in medical imaging: Imaging traits, surrogate endpoints and applications*. Proceedings of the IEEE.
- *Agarwal, L., & Verma, B. (2025). Advanced Chest X-Ray Analysis via Transformer-Based Image Descriptors and Cross-Model Attention Mechanism. ArXiv, abs/2504.16774.*

Información adicional (opcional):

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Contexto del problema:	El proyecto se enmarca en la tendencia global de **Salud 4.0**. Existe la posibilidad de orientar el trabajo hacia el desarrollo de un **artículo científico** para congresos de IA médica (como MICCAI). El enfoque es eminentemente práctico, utilizando repositorios internacionales de acceso abierto como **The Cancer Imaging Archive (TCIA)** para garantizar la relevancia clínica de los resultados.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	• **Lenguajes:** Python (uso avanzado). • **Librerías de ML/DL:** PyTorch o TensorFlow/Keras. • **Tratamiento de imagen:** OpenCV, SimpleITK o Pydicom (para manejo de archivos DICOM). • **Técnicas:** Transfer Learning, Data Augmentation, y arquitecturas de segmentación/clasificación (ResNet, U-Net o ViT).
+ Información	Se valorará positivamente el interés del alumno en la **IA Explicable (XAI)**, es decir, que el modelo no solo detecte el tumor, sino que genere mapas de calor (ej. Grad-CAM) que indiquen al médico en qué zona de la imagen se basa la predicción para aumentar la confianza en el sistema.

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Dr. Diego Fernández García**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

GenAI para extracción avanzada de información documental y visualización

Descripción del problema a abordar

El presente proyecto tiene como objetivo diseñar e implementar una solución basada en inteligencia artificial generativa capaz de extraer información no sensible contenida en documentos empresariales como hojas de cálculo, documentos de texto y presentaciones (archivos Excel, Word o PowerPoint).

La solución permitirá analizar automáticamente estos documentos, identificar información relevante y estructurarla, facilitando su posterior explotación y análisis.

Para ello, se desarrollará una arquitectura en la nube utilizando la nube de Microsoft Azure, que proporcionará la infraestructura necesaria para el procesamiento de los documentos, la ejecución de los modelos de inteligencia artificial y el almacenamiento seguro de los datos extraídos.

La información identificada y procesada será almacenada en una base de datos centralizada, diseñada para permitir la consulta, trazabilidad y reutilización de los datos generados. Posteriormente, estos datos podrán visualizarse y analizarse mediante cuadros de mando interactivos en Microsoft Power BI, permitiendo a los usuarios obtener insights de forma rápida y sencilla.

La arquitectura se diseñará siguiendo principios de escalabilidad, seguridad y gobierno del dato, garantizando que únicamente se procese información no sensible y que el sistema pueda evolucionar con nuevas funcionalidades en el futuro. La selección específica de tecnologías, servicios y modelos de inteligencia artificial se realizará en fases posteriores del proyecto, una vez definidos los requisitos detallados y los casos de uso prioritarios.

Información adicional (opcional):

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Contexto del problema:	Se dispone de presentaciones power point, words y Excel con el contenido de propuestas y, a través de IA Generativa, se espera poder extraer la información tecnológica de los distintos tipos de ficheros. Para el alcance del proyeto, aun por definir, se podrán utilizar 2 o 3 documentos de cada tipo y poder analizar la viabilidad de los formatos para este propósito.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	IA, IA Generativa, base de datos, PowerBI, Microsoft Azure, Github Copilot (no necesaria experiencia previa)
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Guillermo Torralba Elipe**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Emulador de espectros estelares basado en flow matching

Descripción del problema a abordar

Se pretende desarrollar un emulador de espectros estelares que estén basados en flow matching que sea capaz de generar espectros de resoluciones distintas a partir de parámetros estelares como son la temperatura efectiva, la gravedad y abundancias químicas.

Para la construcción del emulador se utilizarán simulaciones con las que contrastar los resultados.

Para este primer piloto, se utilizará la región en longitud de onda abarcado por el RVS de Gaia.

Los pasos a seguir serán:

- Generar una base de datos de entrenamiento usando iSpec variando parámetros como Teff, logg, [M/H]. Posiblemente, también, abundancias.

- Implementar la arquitectura de la red.

- Evaluar la precisión del emulador frente a un conjunto de test generado por iSpec.

- Demostrar la capacidad del modelo para interpolar en un grid arbitrario.

Información adicional (opcional):

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Contexto del problema:	
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Programación en Python. Pytorch, numpy, pandas.
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Guillermo Torralba Elipe**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Búsqueda de funciones de activación parametrizables

Descripción del problema a abordar

En general, las funciones de activación utilizadas en el aprendizaje profundo suelen ser estáticas. Existen algunas activaciones parametrizables como PReLU, pero con poca capacidad de representación, que limita la capacidad de las redes neuronales a adaptar su topología a la complejidad de los datos.

Recientemente, se han propuesto funciones de activación con mayor libertad (splines), por ejemplo, en las redes Kolmogorov-Arnold (KAN). Sin embargo, estas redes tienen un coste computacional alto.

En este proyecto se analizará el uso de funciones matemáticas "universales" como funciones de activación en redes neuronales. Se compararán las implementaciones con arquitecturas convencionales basadas en ReLU, GeLU y KAN.

En particular, se harán las siguientes pruebas:

- Uso de la red para aprender funciones con gradientes complejos (Runge o sinh) y comparación con arquitecturas basadas en activaciones "estándar".

- Estudio de la superficie de pérdida (suavidad del entrenamiento).

- Estudio del desvanecimiento del gradiente mediante la monitorización de la magnitud del gradiente en capas profundas.

En caso de disponer de tiempo:

- Se introducirán estas activaciones en arquitecturas estándar y se evaluarán sobre conjuntos de datos conocidos como MNIST, CIFAR-100.

- Se aplicará para encontrar soluciones a la ecuación del calor.

Bibliografía:

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Abramowitz, M., & Stegun, I. A. (1964). Handbook of Mathematical Functions.

.Liu, Z., et al. (2024). KAN: Kolmogorov-Arnold Networks. arXiv:2404.19756.

Raissi, M., et al. (2019). Physics-informed neural networks. Journal of Computational Physics.

Información adicional (opcional):

Contexto del problema:	
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	PyTorch.
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Guillermo Torralba Elipe**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Clasificador de SED basado en HDC

Descripción del problema a abordar

El objetivo es desarrollar un clasificador de estrellas variables basado en computación hiperdimensional (HDC) con alta precisión que sea capaz de determinar la naturaleza de un objeto emisor de fotones de altas energías (mediante clasificación o mediante agrupación)

Objetivos específicos:

- Desarrollar el codificador que transforme SEDs en vectores bipolares.

- Evaluar la robustez del clasificador frente a pérdida de datos.

- Estimar la incertidumbre de la clasificación mediante métricas en el hiperespacio que se trasladen al espacio original.

- Optimización de hiperparámetros.

Información adicional (opcional):

Contexto del problema:	

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Programación en Python. Descarga de datos reales.
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Víctor Monzón Baeza**
Codirector[1]:	**N/A**
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Modulación y codificación adaptativa para redes no terrestre usando predicción basada en IA a bordo de satélites LEO.

Descripción del problema a abordar

El crecimiento del Internet de las Cosas ha impulsado la necesidad de proporcionar conectividad en entornos remotos donde las redes terrestres no están disponibles. En este contexto, las comunicaciones no terrestres (NTN), especialmente mediante satélites en órbita baja (LEO), han emergido como una solución clave para habilitar servicios IoT a escala global. Tecnologías como NB-IoT resultan especialmente adecuadas para estos escenarios debido a su bajo consumo energético y su capacidad para soportar dispositivos de baja complejidad. Sin embargo, cuando estas tecnologías se trasladan al dominio satelital, aparecen nuevos desafíos que no existen en redes terrestres, como la conectividad intermitente derivada del movimiento orbital de los satélites, los elevados retardos y las limitaciones energéticas tanto en los dispositivos como en las propias cargas útiles del satélite.

Uno de los principales problemas en este tipo de sistemas es la dificultad para adaptar de forma eficiente los parámetros de transmisión a las condiciones del canal. En particular, los mecanismos de Adaptive Coding and Modulation (ACM), ampliamente utilizados en comunicaciones satelitales, dependen de estimaciones del estado del canal que suelen llegar con retardo debido a la naturaleza de los enlaces satelitales. Esta latencia, unida a la alta variabilidad del canal en entornos LEO, provoca que las decisiones de selección de modulación y codificación no siempre sean óptimas. Como consecuencia, se producen pérdidas de eficiencia, aumento del número de retransmisiones y, en última instancia, un mayor consumo energético, que es un factor crítico en dispositivos IoT alimentados por batería.

En paralelo, la irrupción de técnicas de inteligencia artificial en el ámbito de las comunicaciones está abriendo nuevas posibilidades para abordar estos problemas desde un enfoque predictivo. En lugar de reaccionar a las condiciones actuales del canal, los modelos de aprendizaje automático permiten anticipar su evolución a partir de datos históricos, patrones de tráfico y variables contextuales. Este cambio de paradigma es especialmente relevante en redes NTN, donde la previsibilidad de ciertos fenómenos, como las ventanas de visibilidad de los satélites o la evolución temporal del canal, puede ser explotada para optimizar la toma de decisiones. De hecho, trabajos recientes han demostrado que el uso de modelos como LSTM permite alinear el comportamiento de los dispositivos con las oportunidades reales de transmisión, logrando reducciones significativas en el consumo energético sin comprometer la disponibilidad de los datos.

Además, el avance en hardware especializado para inteligencia artificial está haciendo viable trasladar parte de este procesamiento directamente al segmento espacial. El concepto de procesamiento a bordo mediante inferencia de modelos previamente entrenados en tierra permite reducir la dependencia de decisiones centralizadas y

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

minimizar los retardos asociados al control desde estaciones terrestres. Esta capacidad abre la puerta a sistemas satelitales más autónomos, capaces de adaptar dinámicamente parámetros de transmisión como el MODCOD en función de predicciones locales del estado del canal o de la demanda de tráfico, mejorando así tanto la eficiencia espectral como el consumo energético global del sistema.

En este contexto, surge la oportunidad de integrar técnicas de predicción basadas en inteligencia artificial con mecanismos clásicos de adaptación de enlace, con el objetivo de optimizar el rendimiento de comunicaciones NB-IoT sobre satélites LEO. Este enfoque combina conocimientos de comunicaciones digitales, modelado de canal y aprendizaje automático, y se enmarca dentro de las tendencias actuales hacia sistemas de comunicaciones más inteligentes, autónomos y eficientes, especialmente relevantes en aplicaciones IoT a gran escala donde la energía y la capacidad de adaptación son factores determinantes.

Los sistemas **NB-IoT sobre redes NTN (LEO)** presentan un gran desafío:

- **Conectividad intermitente** (ventanas de visibilidad cortas): supone un reto para transmitir datos.
- **Retrasos elevados** → feedback lento para ACM: perdemos oportunidad de transmitir datos de sensores
- **Dispositivos con energía muy limitada:** impuesta por dispositivos bajo coste como son dispositivos IoT.
- **Payload satelital con restricciones de potencia:** son satélites pequeños

Actualmente:

- El **ACM (Adaptive Coding and Modulation)** depende de estimaciones de canal con retardo
- Esto provoca:
    1. Selección subóptima de MODCOD (conjunto modulador+codificador)
    2. Mayor consumo energético (retransmisiones, sobredimensionamiento)

El problema clave:

¿Cómo optimizar la selección de MODCOD en enlaces IoT satelitales LEO minimizando el consumo energético, usando predicción inteligente y procesamiento a bordo?

Referencias:

Ortiz, F., Monzon Baeza, V., Garces-Socarras, L. M., Vásquez-Peralvo, J. A., Gonzalez, J. L., Fontanesi, G., ... & Chatzinotas, S. (2023). Onboard processing in satellite communications using ai accelerators. *Aerospace*, *10*(2), 101.

Fontanesi, G., Ortíz, F., Lagunas, E., Baeza, V. M., Vázquez, M. Á., Vásquez-Peralvo, J. A., ... & Chatzinotas, S. (2023). Artificial intelligence for satellite communication and non-terrestrial networks: A survey. *arXiv preprint arXiv:2304.13008*.

Monzon Baeza, V., Ortiz, F., Herrero Garcia, S., & Lagunas, E. (2022). Enhanced communications on satellite-based IoT systems to support maritime transportation services. *Sensors*, *22*(17), 6450.

Baeza, V. M., Rigazzi, G., Romero, S. A., Ferrus, R., Ferrer, J., Mhatre, S., & Guadalupi, M. (2024, September). IoT-NTN communications via store-and-forward core network in multi-LEO-satellite deployments. In *2024 IEEE 35th International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC)* (pp. 1-6). IEEE.

Información adicional (opcional):

Contexto del problema:	El tema forma parte de una línea de investigación actúal iniciada con otros estudiantes. Con este tema se pretende dar continuidad a trabajos ya realizados para mejorar las comunicaciones por satélites utilizando dispositivos de bajo coste y bajo consumo como sensores IoT. Posible publicación en revista de IEEE.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	**Herramientas** • Python (obligatorio) ○ PyTorch / TensorFlow ○ scikit-learn • MATLAB (opcional para canal) • Simulación: ○ dataset sintético o TLE reales Técnicas: ▪ LSTM (clave para series temporales) ▪ Random Forest / XGBoost (baseline) ▪ Deep Learning: • RNN • Transformers • Reinforcement Learning (opcional TOP) Otras técnicas de redes neuronales pueden ser igualmente válidas Metodología incluye: formar/crear un dataser inicial o a partir de otros menores componer un dataset para este tipo de escenarios. Modelos a comparar Baseline: ACM clásico (threshold SNR) ML: LSTM, RF, ESN, g(opcional) DRL

+ Información	

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Carlos Rubert Escuder**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Visual Thinking educativo con modelos de lenguaje compactos: generación automática de diagramas desde texto curricular y evaluación por corrección estructural y utilidad didáctica

Descripción del problema a abordar

Este TFM aborda el desarrollo de un sistema de IA capaz de transformar un texto curricular (explicación, procedimiento, tema o fragmento de unidad didáctica) en una representación visual útil para aprendizaje: diagrama de flujo, secuencia, mapa conceptual sencillo o esquema jerárquico.

El problema técnico se plantea como generación estructurada: en lugar de producir una imagen directamente, el sistema genera una descripción formal del diagrama en un lenguaje textual de diagramación (por ejemplo, Mermaid, PlantUML o DOT/Graphviz), que luego se valida (sintaxis) y se renderiza de forma reproducible.

La contribución incluye comparar modelos compactos en su capacidad de generar (a) código de diagrama válido, (b) representaciones fieles al contenido, y (c) esquemas comprensibles con baja carga cognitiva.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Información adicional (opcional):

Contexto del problema:	En la adaptación NESE, lo visual puede apoyar la comprensión si el diagrama es claro, jerárquico y evita saturación. Sin embargo, un diagrama incorrecto o confuso introduce errores conceptuales difíciles de detectar. Por ello, este TFM se centra en: (1) control estructural (validación automática), (2) trazabilidad y revisión docente (el diagrama es texto versionable), y (3) evaluación didáctica (utilidad para ESO). El trabajo se alinea con el enfoque del máster en diseñar soluciones de IA considerando rendimiento e interacción y con el diseño de interacciones naturales, además de requerir rigor experimental en la evaluación y capacidad de interpretar resultados con criterio.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	1. Representación estructurada y lenguajes de diagramación • Mermaid: sintaxis de diagramas de flujo, secuencia, mindmap y otros; validación de sintaxis como señal objetiva de calidad mínima. • PlantUML: alternativas de diagramación (UML y no UML), y ventajas/inconvenientes en contexto educativo. • DOT/Graphviz: representación de grafos y árboles con reglas formales; útil para mapas conceptuales. 2. Generación controlada con restricciones • Plantillas de salida (formato fijo) para asegurar consistencia: título, nodos, relaciones, jerarquías y notas. • Estrategias de "repair": cuando el modelo genera un diagrama con error de sintaxis, aplicar reparación automática (regeneración guiada, autocorrección con validadores). • Generación "por pasos": primero extraer conceptos y relaciones (estructura intermedia), después producir el código Mermaid/PlantUML. 3. Modelos compactos y protocolo comparativo • Criterios de selección de modelos candidatos: capacidad en español, tamaño, licencia, facilidad de ejecución local, estabilidad en generación estructurada. • Comparación en igualdad de condiciones: mismas entradas, mismo tipo de diagrama, misma restricción de longitud y misma métrica de evaluación. 4. Evaluación de diagramas (tres niveles) • Corrección sintáctica (automática): porcentaje de diagramas renderizables sin error. • Fidelidad semántica (automática y humana): cobertura de conceptos clave y relaciones esenciales; penalización por relaciones inventadas. • Utilidad didáctica (humana): claridad visual, jerarquía adecuada, ausencia de redundancia, y adecuación a ESO/NESE. 5. Implementación y pipeline reproducible • Entorno Python para la orquestación: extracción, generación, validación y render.

	• Renderizado reproducible: por ejemplo, CLI oficial de Mermaid o librerías equivalentes; generación de imágenes para su integración en materiales. • Registro de artefactos: entradas, diagrama generado (texto), resultado de validación, imagen renderizada y métricas.
+ Información	Bibliografía Inicial: • Wei, J., et al. (2025). *From Words to Structured Visuals: A Benchmark and Framework for Text-to-Diagram Generation and Editing*. • Shbita, B., et al. (2025). *MermaidSeqBench: An Evaluation Benchmark for LLM-to-Mermaid Sequence Diagram Generation*. • Nguyen, J., et al. (2026). *Class Model Generation from Requirements using Large Language Models*. • De Bari, D., Garaccione, G., Coppola, R., Torchiano, M., & Ardito, L. (2024, October). Evaluating large language models in exercises of uml class diagram modeling. • Krishnan G. S., N., et al. (2025). *Comparative Analysis of Large Language Models for Automated Use Case Diagram Generation*. SciTePress. • Liu, Z., et al. (2022). *Code Generation From Flowcharts with Texts*. Findings of EMNLP 2022. • Wang, H., et al. (2025). Code-vision: evaluating multimodal LLMs logic understanding and code generation capabilities • Bates, A., et al. (2025). *Unified modeling language code generation from diagram images using multimodal large language models* • Galletti, M., et al. (2025). *Automated Concept Map Extraction from Text*. • Zhai, X., et al. (2025). *A Systematic Review of Concept Map Generation*. • dos Santos, V., et al. (2018). Concept maps construction using natural language processing to support studies selection

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Carlos Rubert Escuder**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Selección y optimización de inferencia de modelos de lenguaje compactos en CPU para entornos educativos con recursos limitados

Descripción del problema a abordar

El TFM plantea un problema de ingeniería y evaluación: cómo elegir, entre varios modelos de lenguaje de pocos parámetros, aquel que ofrece el mejor equilibrio entre calidad y coste computacional cuando se ejecuta en CPU (sin depender de nube).

No se trata solo de "que funcione", sino de cuantificar de forma reproducible el impacto de cada decisión técnica (modelo candidato, cuantización, formato, motor de inferencia, tamaño de contexto y parámetros de generación) sobre métricas de rendimiento (latencia, tokens por segundo, memoria) y sobre métricas de calidad en tareas educativas (p. ej., simplificación y redacción clara para Educación Secundaria-ESO, fidelidad al contenido, cumplimiento de restricciones).

Delimitación y objetivos académicos

1. Definir un marco de comparación (banco de pruebas) que permita evaluar modelos compactos de forma justa en CPU.
2. Seleccionar un conjunto de modelos candidatos comparables (por ejemplo, 0,5–3B parámetros), aplicando criterios explícitos: idioma, licencia, requisitos de memoria, compatibilidad con cuantización y disponibilidad de tokenizador.
3. Implementar y comparar al menos dos estrategias de optimización de inferencia, por ejemplo:
   - Cuantización de pesos (distintos niveles, con medición de degradación de calidad).
   - Distintos motores o formatos de ejecución en CPU (según compatibilidad), manteniendo el mismo banco de pruebas.
4. Proponer una recomendación final argumentada (modelo + configuración + motor) y documentarla para su uso en un copilot docente local.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Información adicional (opcional):

Contexto del problema:	El contexto es el desarrollo de un copilot docente local, pensado para situaciones reales donde el hardware disponible puede ser un portátil de gama media, un mini-PC o un equipo de aula sin aceleración por GPU. En ese escenario, el requisito de rendimiento condiciona la viabilidad del uso en clase y la experiencia docente. Además, al tratarse de un sistema aplicado a educación, la evaluación debe incorporar dimensiones de responsabilidad: transparencia sobre limitaciones, trazabilidad de configuraciones y análisis de riesgos derivados de salidas incorrectas o no adecuadas. Esto encaja con el enfoque del máster en: • Identificación de requisitos de seguridad, rendimiento e interacción con humanos y el diseño de soluciones que los cumplan • Evaluación del rendimiento en función de técnicas, datos y contexto de ejecución • Selección de herramientas, dispositivos y plataformas Posibilidad de desarrollo de artículo científico
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	A) Métricas y metodología de evaluación • Diseño de experimentos en sistemas de IA: control de variables, comparación por condiciones equivalentes, repetición con semillas, y análisis de sensibilidad (ablasiones). • Métricas de rendimiento: latencia por petición, tokens por segundo, tiempo de arranque, consumo de memoria pico, estabilidad térmica en cargas prolongadas. • Métricas de calidad para tareas educativas: fidelidad al texto fuente, preservación terminológica, cumplimiento de restricciones de longitud/estructura, y evaluación humana mínima con rúbrica. B) Optimización de inferencia en CPU • Cuantización post-entrenamiento (en distintos formatos) y análisis de degradación calidad-rendimiento. • Motores de inferencia en CPU y formatos de serialización/ejecución (según el conjunto de modelos candidatos): ejecución directa en PyTorch/Transformers, rutas con formatos optimizados, y variantes basadas en ONNX cuando sea viable. • Perfilado y paralelismo en CPU: ajuste de hilos, afinidad, y coste de memoria frente a rendimiento. C) Ingeniería de software y reproducibilidad • Entornos aislados (conda), control de dependencias, trazabilidad de configuraciones y resultados. • Registro estructurado de experimentos (metadatos por corrida, configuración, métricas, artefactos) para poder defender resultados ante tribunal. D) Conocimiento aplicado a PLN: Aunque este TFM se centra en inferencia, el estudiante debe comprender qué está ejecutando: tokenización, ventana de contexto, estrategia de generación y sus efectos, y particularidades de modelos de lenguaje.

+ Información	Bibliografía inicial (orientativa) • Hu, E. J., et al. (2021). *LoRA: Low-Rank Adaptation of Large Language Models*. arXiv:2106.09685. • Dettmers, T., et al. (2023). *QLoRA: Efficient Finetuning of Quantized LLMs*. arXiv:2305.14314. • Frantar, E., et al. (2022). *GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers*. arXiv:2210.17323. • Lin, J., et al. (2023). *AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration*. arXiv:2306.00978. • ONNX Runtime (documentación). *Model Optimizations y Quantization* (cuantización post-entrenamiento y optimizaciones para CPU). • Literatura metodológica sobre evaluación reproducible y control de variables en sistemas de aprendizaje automático.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Raúl Homero Llasag Rosero**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Onboarding inteligente de empleados en Microsoft Teams con soporte de Atlassian

Descripción del problema a abordar

La incorporación de nuevos empleados constituye un proceso crítico para la productividad y la retención de talento en las organizaciones modernas. Sin embargo, los métodos tradicionales de onboarding suelen ser manuales, fragmentados y poco eficientes. Este proyecto propone el diseño y desarrollo de un **bot conversacional para Microsoft Teams**, integrado con soluciones Atlassian (Jira y Confluence), con el fin de **automatizar y optimizar el proceso de incorporación de empleados**. El bot permitirá asignar tareas, proporcionar acceso a documentación corporativa y gestionar listas de verificación en un entorno colaborativo, reduciendo tiempos y mejorando la experiencia del usuario.

La propuesta se fundamenta en trabajos recientes que destacan el uso de **chatbots corporativos en plataformas de colaboración** para la automatización de flujos de trabajo [1-2], así como en investigaciones sobre la integración de herramientas de gestión de proyectos en entornos digitales de recursos humanos [3-4]. Se espera que la solución aporte beneficios en términos de eficiencia organizacional, reducción de errores y mayor satisfacción de los empleados durante su incorporación.

Este enfoque combina **tecnologías de colaboración empresarial, automatización de procesos y gestión del conocimiento**, alineándose con las tendencias actuales en digitalización de recursos humanos y transformación organizacional.

Referencias

- [1] Microsoft, "Build bots for Microsoft Teams," Microsoft Learn, 2024. [Online]. Available: https://learn.microsoft.com/en-us/microsoftteams/platform/bots/ (learn.microsoft.com in Bing)
- [2] Atlassian, "Microsoft Teams integrations with Jira, Confluence, and Trello," Atlassian Documentation, 2025. [Online]. Available: https://support.atlassian.com

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

- [3] C. H. Kennedy, A. Hilal, and M. Momeni, "The Role of Federated Learning in Improving Financial Security: A Survey," *arXiv preprint* arXiv:2510.14991, 2025. [Online]. Available: https://arxiv.org/abs/2510.14991
- [4] M. Emmanuel, "Federated Learning for Privacy-Preserving Financial Fraud Detection," *SSRN*, May 20, 2025. [Online]. Available: https://ssrn.com/abstract=5399668 doi: 10.2139/ssrn.5399668

Información adicional (opcional):

Contexto del problema:	Alto potencial de ser aplicado en varias empresas en el área financiera y en el desarrollo de software.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	• **Chatbots y NLP** ○ Diseño de diálogos y flujos conversacionales. ○ Procesamiento de lenguaje natural (NLP). • **Arquitectura de Software** ○ Microservicios y APIs REST. ○ Seguridad y autenticación (OAuth 2.0, SSO). ○ Escalabilidad en entornos cloud (Azure, AWS).
+ Información	• **Microsoft Teams Development** ○ SDK y APIs de Teams para bots. ○ Adaptive Cards y flujos conversacionales. ○ Integración con servicios externos vía Microsoft Graph. • **Atlassian Solutions** ○ **Jira**: gestión de tareas, incidencias y proyectos. ○ **Confluence**: documentación y gestión del conocimiento. ○ APIs de Atlassian para integración con terceros.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ruth Palmero Sánchez**
Codirector[1]:	**Sergio Mauricio Martinez Monterrubio**

La propuesta se adapta a TFE grupal	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta (Máximo 20 palabras).

Hacia una IA más sostenible: MLOPs y técnicas de IA eficiente

Descripción del problema a abordar (Máximo 300 palabras).

La expansión acelerada de la inteligencia artificial está generando un incremento sin precedentes en el consumo energético global. En la actualidad, la IA ya representa alrededor del 2% del consumo eléctrico mundial, con datos que muestran que los centros de datos asociados generan entre 2,5% y 3,7% de las emisiones globales de gases de efecto invernadero, superando incluso al sector de la aviación.

Las proyecciones para los próximos años son aún más preocupantes: para 2026, la IA podría consumir casi la mitad de toda la electricidad destinada a centros de datos a nivel global, y para 2030 su demanda podría más que duplicarse hasta alcanzar cerca del 3% del consumo eléctrico mundial. En este contexto, se hace necesario investigar enfoques que permitan **reducir la huella ambiental del entrenamiento de modelos de IA** sin comprometer la calidad de los resultados.

En este contexto, el campo de Model Compression & Efficient AI se centra en desarrollar técnicas que reduzcan el tamaño, el cómputo y los recursos necesarios para ejecutar modelos, manteniendo una precisión comparable a la de sus versiones originales. Estas técnicas incluyen métodos como pruning (eliminación de parámetros innecesarios), quantization (reducción de la precisión numérica), knowledge distillation (transferencia del conocimiento de un modelo grande a uno más pequeño), y low-rank factorization, entre otras.

El objetivo común de todas ellas es construir modelos más ligeros, más rápidos y menos exigentes desde el punto de vista computacional. Este enfoque es clave para la sostenibilidad porque disminuye directamente el uso de CPU, GPU y memoria, lo que a su vez reduce el consumo energético y la huella de carbono asociada al procesamiento. Además, los modelos comprimidos permiten ejecutar la IA en dispositivos de bajo consumo —

[1] Únicamente en el caso de doctorando y que no sea pdi de la universidad.

como móviles, sensores IoT o microcontroladores— evitando la necesidad de depender de centros de datos de gran tamaño, cuya demanda energética es considerable.

Desde la perspectiva medioambiental, **Model Compression & Efficient AI** ofrece un doble beneficio: por un lado, reduce los recursos necesarios para entrenar modelos complejos, y por otro, disminuye el coste energético durante la inferencia, que es la fase más repetida y acumulativa en sistemas de IA desplegados a gran escala. Esto lo convierte en un área especialmente alineada con los principios del Green Software, donde se promueve el diseño de sistemas digitales eficientes y respetuosos con el entorno.

El proyecto que se propone consiste en:

1. Diseñar un pipeline automatizado para comparar el coste energético del entrenamiento y la inferencia entre modelos originales y modelos comprimidos, incorporando métricas de huella de carbono y eficiencia computacional.

Este objetivo técnico obliga a:

- instrumentar el proceso de entrenamiento para capturar energía consumida por CPU/GPU,
- integrar un sistema de logging energético en cada etapa del pipeline,
- desarrollar scripts reproducibles para comparar configuraciones,
- obtener métricas como energía por época, energía por predicción, CO_2 estimado y reducción porcentual respecto al modelo original.

Bibliografía:

Palmero, R. (05 de marzo de 2025). ¿Qué es el Green Software? https://www.adrformacion.com/blog/que_es_el_green_software.html

Currie, A., Hsu, S., & Bergman, S. (2024). Building green software: A sustainable approach to software development and operations. O'Reilly Media

Paula, E., Soni, J., Upadhyay, H., & Lagos, L. (2025). Comparative analysis of model compression techniques for achieving carbon efficient AI. Scientific Reports. https://www.nature.com/articles/s41598-025-07821-w.pdf

Vilar Dantas, P., da Silva Jr., W. S., Cordeiro, L. C., & Carvalho, C. B. (2024). A comprehensive review of model compression techniques in machine learning. Applied Intelligence, 54, 11804–11844. https://doi.org/10.1007/s10489-024-05747-w

Chaurasiya, R., & Sharma, V. (2025). Energy-efficient deep learning via compression: Green AI. International Journal of Scientific Research & Engineering Trends, 11(3). https://ijsret.com/wp-content/uploads/IJSRET_V11_issue3_1143.pdf

Stow, M., & Stewart, A. A. (2025). Reducing carbon footprint of machine learning through model compression and pruning. International Journal of Innovative Science and Research Technology, 10(8), 1479–1503. https://doi.org/10.38124/ijisrt/25aug970

Mei, L., & Stamp, M. (2025). Energy considerations for large pretrained neural networks. arXiv:2506.01311. https://arxiv.org/pdf/2506.01311

Información adicional (opcional):

Contexto del problema (Máximo 100 palabras):	El proyecto se podría incorporar como herramienta Open Source de la Green Software Foundation y ser diseminada por dicha organización.
Conceptos que el alumno debe dominar (ítems)	El alumnado deberá de aprender conceptos sobre Green Software y Green AI, de ahí que la primera tarea sea la de llevar a cabo un SotA, dado que no será común que los comprendan.
+ Información	Dado que el enfoque es genérico, se puede proponer a varios grupos, dado que le pueden dar un contexto diferente. Finalmente, para un Trabajo de Fin de Máster, esta línea es especialmente atractiva porque permite desarrollar experimentos reales y reproducibles con recursos modestos. Es posible entrenar y comprimir modelos pequeños en un portátil, medir su consumo energético con herramientas open-source y demostrar mejoras cuantificables en eficiencia sin necesidad de acceso a grandes infraestructuras. Esto convierte a *Model Compression & Efficient AI* en una opción sólida, viable y con impacto real para estudiar cómo la IA puede evolucionar hacia prácticas más sostenibles.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Raúl Homero Llasag Rosero**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Pronósticos escalables y descentralizados para sistemas críticos de seguridad con recursos computacionales limitados

Descripción del problema a abordar

Los sistemas críticos de seguridad —como los de transporte ferroviario, marítimo y otros— suelen estar equipados con componentes de baja capacidad de procesamiento, almacenamiento y transmisión de datos. A pesar de estas limitaciones, dichos sistemas requieren la adopción de estrategias de gestión basadas en inteligencia artificial para reducir costos y aumentar la productividad de las flotas de transporte. Ejemplos de estas estrategias incluyen el **mantenimiento basado en condiciones de salud (CBM)** y el **pronóstico y gestión de la salud (PHM)** [1].

La implementación de modelos predictivos de inteligencia artificial en este contexto enfrenta un desafío adicional: el conocimiento necesario se obtiene a partir de múltiples vehículos del mismo tipo que se encuentran físicamente dispersos [2]. En este escenario, el **aprendizaje federado** surge como una solución prometedora, al permitir la captura y agregación de información proveniente de diversos sistemas de sensores cibernéticos [3]. Estos sistemas pueden transmitir periódicamente conocimiento hacia una fuente gestora mediante protocolos de comunicación multiplataforma, como **gRPC** [3] o **WebSockets** [4].

Este proyecto propone la simulación de un entorno federado compuesto por varios sistemas aislados de una flota, cada uno procesando información parcial de un conjunto de datos diseñado para predecir la vida útil de componentes críticos. Asimismo, se plantea comparar el rendimiento de gRPC y WebSockets en la transmisión y agregación de conocimiento dentro de un modelo federado, evaluando su eficiencia y escalabilidad en condiciones de recursos computacionales limitados.

Bibliografía

- [1] V. Ulansky and A. Raza, "A historical survey of condition-based maintenance models with imperfect inspections: Cases of constant and non-constant probabilities of inspection outcomes," Reliability Engineering & System Safety, vol. 254, p. 110544, 2025, doi: 10.1016/j.ress.2024.110544.
- [2] R. Llasag Rosero, C. Silva, B. Ribeiro, M. Albisser, M. Brutsche, and M. Arias Chao, “Label synchronization strategies for hybrid federated learning,” Reliability Engineering & System Safety, vol. 256, p. 110751, 2025. doi: 10.1016/j.ress.2024.110751.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

- [3] J. Tupayachi, A. N. Khan, and X. Li, "Scalable decentralized prognostics for industrial systems under data heterogeneity," Computers and Electrical Engineering, vol. 133, p. 111023, 2026, doi: 10.1016/j.compeleceng.2026.111023.
- gRPC Authors, "gRPC," [Online]. Available: https://grpc.io/. [Accessed: Mar. 15, 2026].
- Mozilla Developer Network, "WebSockets API," [Online]. Available: https://developer.mozilla.org/en-US/docs/Web/API/WebSockets_API. [Accessed: Mar. 15, 2026].

Información adicional (opcional):

Contexto del problema:	Proyecto con potencial de innovación y divulgación científica en múltiples revistas y conferencias, como, por ejemplo: • PHMe2026 - 9th European Conference of the Prognostics and Health Management Society (8-7-2026, Oslo), https://phm-europe.org/ • Journal of Intelligent Manufacturing • Journal of Realibility Engineering and System Safety • MDPI Aerospace
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	• Redes neuronales • Modelos predictivos • Mantenimiento basado en el estado de la salud (CBM) • Prognóstico y gestión de la salud (PHM) • Predicción y pronóstico
+ Información	• Sistemas críticos de seguridad (Safety-Critical Systems) • Reglamento de Inteligencia Artificial de la Unión Europea (AI Act) • Estándares para sistemas de Inteligencia Artificial, como ISO 42000 y otros.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Carlos Rubert Escuder**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Asistente docente DUA-A basado en recuperación de fuentes y generación controlada: trazabilidad, verificación y comparación de modelos compactos en CPU

Descripción del problema a abordar

El TFM propone diseñar y evaluar un asistente docente que adapte un material de ESO a variantes textuales alineadas con DUA-A, pero incorporando dos requisitos técnicos adicionales: (1) que la salida sea trazable (cada afirmación relevante debe poder vincularse a fragmentos del material consultado) y (2) que el sistema reduzca afirmaciones no sustentadas mediante verificaciones automáticas.

La contribución académica se centra en arquitectura, control de salida y evaluación reproducible, comparando varios modelos compactos (pocos parámetros) en igualdad de condiciones.

Para evitar que la anotación (generación del corpus) sea el núcleo del TFM, el sistema se apoya principalmente en recuperación de fuentes y en plantillas de salida, y limita la creación manual de datos a lo imprescindible:

1. Base documental acotada (principal insumo “no anotado”)
    - Un repositorio de materiales de ESO (por ejemplo, 50–150 fragmentos) con metadatos simples: asignatura, tema, curso, fuente. No requiere crear “pares” de simplificación. La arquitectura RAG usa esta base como referencia.

2. Conjunto de evaluación congelado (pequeño y controlado)
    - 20–40 entradas de prueba, cada una con: (a) el fragmento fuente, (b) una lista corta de “hechos imprescindibles” (3–6 ítems) y (c) restricciones DUA-A que se van a pedir (nivel lector, estructura, glosario). Esta lista de hechos se puede construir con apoyo del propio material (no exige formación previa en NESE; exige rigor en fidelidad). El objetivo es evaluar cobertura y fidelidad.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

3. Dataset mínimo para “formato con trazabilidad” (opcional, 40–80 ejemplos)
    - Si se decide ajustar el modelo, el dataset no busca enseñar contenido, sino un formato: salida estructurada + marcas de cita a fragmentos recuperados. La referencia (qué fragmentos se citaron) se obtiene del propio sistema de recuperación, lo que reduce trabajo manual.

Información adicional (opcional):

Contexto del problema:	DUA-A plantea que, para lograr accesibilidad cognitiva, conviene disminuir la dependencia de la memorización, usar formatos complementarios (visual, auditivo, multimedia), reducir la necesidad de habilidades organizativas complejas y ajustar vocabulario y nivel lector al nivel de comprensión del alumnado. En la parte de acceso a la información, se enfatiza presentar la información ordenada, eliminando “ruido”, y disponer de materiales con distintos grados de complejidad conceptual; además, se recomienda aplicar criterios para hacer accesibles los textos, por ejemplo mediante lectura fácil. Un LLM compacto no sustituye al diseño didáctico completo, pero sí puede cubrir de manera realista un subconjunto de actuaciones DUA-A basadas en texto: reescritura con distintos niveles, organización en esquemas, generación de glosarios y preguntas de comprobación, y presentación de la misma información en formatos textuales diferenciados (p. ej., explicación breve, esquema, lista de ideas). Este TFM permite evidenciar, de forma directa, competencias vinculadas a requisitos de rendimiento e interacción y a rigor experimental: requisitos de seguridad, rendimiento e interacción con humanos, interacciones naturales, evaluación del rendimiento según técnica, datos y contexto, herramientas y entornos, integración de técnicas en una solución, rigor y control de errores y consideraciones éticas, sociales y de legalidad. Posibilidad de desarrollar un artículo científico.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	1. Recuperación de información y representación semántica • Segmentación de documentos, creación de índice y búsqueda semántica (embeddings). • Medidas de calidad de recuperación (precisión/cobertura de pasajes relevantes) y análisis de errores de recuperación. 2. Generación controlada alineada con DUA-A (subconjunto tratable por LLM compacto) • Plantillas de salida para: versión estándar, versión simplificada (lectura fácil/lenguaje claro), esquema jerárquico, glosario y preguntas de comprobación. • Restricciones prácticas: longitud máxima, frases cortas, preservación terminológica y "eliminar ruido" (información no necesaria para los objetivos). • Adaptación a nivel lector: aproximar vocabulario al nivel de comprensión, como criterio de accesibilidad cognitiva. 3. Trazabilidad y verificación • Diseño de un formato de salida con citas a fragmentos recuperados (por ejemplo, identificadores de pasaje). • Verificaciones automáticas: detección de frases sin respaldo (no citadas), contraste de términos clave, y avisos cuando falta evidencia. • Registro de configuraciones y resultados para auditoría y replicación. 4. Comparación de modelos compactos y medición en CPU • Selección de 2–4 modelos candidatos (tamaño, licencia, idioma), y protocolo fijo de inferencia. • Métricas: latencia, tokens/segundo, memoria, y métricas de calidad específicas del banco de pruebas (cobertura de hechos, fidelidad, cumplimiento de formato).
+ Información	Bibliografía inicial (orientativa) • Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. • Manakul, P., et al. (2023). SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. • Hu, E. J., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. • Dettmers, T., et al. (2023). QLoRA: Efficient Finetuning of Quantized Large Language Models. • Karpukhin, V., et al. (2020). Dense Passage Retrieval for Open-Domain Question Answering. • Agustí Almela, F. J. et al. (2023). DUA-A: Diseño Universal y Aprendizaje Accesible (2.ª edición). • Guías y literatura de evaluación de sistemas de recuperación y generación (métricas, diseño de rúbricas y análisis de fallos), complementadas con referencias de accesibilidad cognitiva y adaptación de materiales en el ámbito educativo.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Raúl Homero Llasag Rosero**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Evaluación de modelos de lenguaje a gran escala para la predicción del estado de salud de componentes aeronáuticos

Descripción del problema a abordar

El mantenimiento basado en la predicción de la salud (CBM) y el basado en la gestión del pronóstico y la salud (PHM), han sido estrategias altamente valoradas para reducir el costo de mantenimiento y el tiempo de intolerabilidad de sistemas críticos de seguridad en diferentes industrias, como, por ejemplo, la aviación, aeroespacial, marítima entre otras [1-2]. La evolución tecnológica de estas técnicas de mantenimiento se ha dado gracias a la evolución acelerada de la inteligencia artificial predictiva [1]. Sin embargo, desde la diseminación masiva de los modelos generativos de texto, es mínima la literatura que refiere al rol de los grandes modelos de lenguaje (LLMs) en CBM y PHM en el pronóstico de la vida útil de componentes o sistemas críticos de seguridad [3-4] como, por ejemplo, sistemas de refrigeración de aeronaves, turbofans, entre otros.

Este proyecto pretende utilizar conjuntos de datos públicos de la National Aeronautics and Space Administration – NASA [1] y artículos públicos relacionados para dar respuesta en lenguaje natural a la tribulación de cabina y a los técnicos de mantenimiento sobre el estado de la aeronave y las horas de vuelo previstas antes de una falla mecánica. Finalmente, mediante métricas de evaluación cualitativas, se pretende medir la calidad de la información provista por diferentes modelos generativos.

Referencias

- [1] M. Arias Chao, C. Kulkarni, K. Goebel, and O. Fink, “Aircraft Engine Run-to-Failure Dataset under Real Flight Conditions for Prognostics and Diagnostics,” Data, vol. 6, no. 1, p. 5, 2021. doi: 10.3390/data6010005.
- [2] R. Llasag Rosero, C. Silva, B. Ribeiro, M. Albisser, M. Brutsche, and M. Arias Chao, “Label synchronization strategies for hybrid federated learning,” Reliability Engineering & System Safety, vol. 256, p. 110751, 2025. doi: 10.1016/j.ress.2024.110751.
- [3] T. Yu, J. Tang, Q. Yu, et al., “Large language models for PHM: a review of optimization techniques and applications,” Autonomous Intelligent Systems, vol. 5, p. 18, 2025. doi: 10.1007/s43684-025-00100-5.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

- [4] T. Minami, D.-Y. Ji, and L. Jay, "LLMs as Pre-trained Models for Time-Series Applications in PHM," Annual Conference of the PHM Society, vol. 17, no. 1, 2025. doi: 10.36001/phmconf.2025.v17i1.4376.

Información adicional (opcional):

Contexto del problema:	Proyecto con potencial de innovación y divulgación científica en múltiples revistas y conferencias, como, por ejemplo: • PHMe2026 - 9th European Conference of the Prognostics and Health Management Society (8-7-2026, Oslo), https://phm-europe.org/ • Journal of Intelligent Manufacturing • Journal of Realibility Engineering and System Safety • MDPI Aerospace
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	• Redes neuronales • Modelos predictivos y generativos • Prognóstico y gestión de la salud (PHM) • Grandes modelos de lenguaje (LLMs) • Generación aumentada por recuperación (RAG) • Búsqueda por similitud • Modo Agente y Contexto
+ Información	• Mantenimiento basado en condiciones (CBM) • Estimación de la vida útil restante (RUL) • Previsión de series temporales • Procesamiento de señales de sensores • Sistemas y componentes de aviones

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Raúl Homero Llasag Rosero**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Evaluación Automatizada y Explicable de Sistemas RAG en Contextos Multilingües

Descripción del problema a abordar

Los sistemas de **Generación Aumentada por Recuperación (RAG)** combinan modelos de lenguaje con mecanismos de recuperación de información. Su objetivo es mejorar la precisión de las respuestas y reducir las alucinaciones [1]. Sin embargo, evaluar su capacidad de recuperación sigue siendo un desafío. Muchos métodos actuales dependen de evaluaciones manuales y de métricas limitadas [1-2]. Esto implica una fuerte intervención humana en procesos subjetivos y tediosos. Como consecuencia, se dificulta la creación de soluciones que sean reproducibles, explicables y comparables [2]. En **contextos multilingües**, la evaluación se vuelve más compleja debido a diferencias lingüísticas, variaciones semánticas entre idiomas y la disponibilidad desigual de datos [3]. Esto puede afectar tanto la recuperación de información como la calidad de las respuestas generadas. En este contexto, surge la necesidad de **métodos automatizados y explicables para evaluar soluciones RAG en entornos multilingües**, que permitan medir de forma objetiva la calidad de la recuperación, la coherencia de las respuestas y la confiabilidad del sistema.

Referencias

- [1] C. Sharma, *Retrieval-Augmented Generation: A Comprehensive Survey of Architectures, Enhancements, and Robustness Frontiers*. arXiv preprint arXiv:2506.00054, 2025. [Online]. Available: https://arxiv.org/abs/2506.00054
- [2] K. Murugaraj, S. Lamsiyah, and M. Theobald, "RAGVUE: A Diagnostic View for Explainable and Automated Evaluation of Retrieval-Augmented Generation," in *Proceedings of the EACL 2026 Demo Track*, 2026. [Online]. Available: https://https://arxiv.org/html/2601.04196v1
- [3] N. Chirkova, D. Rau, H. Déjean, T. Formal, S. Clinchant, and V. Nikoulina, *Retrieval-augmented generation in multilingual settings*. arXiv preprint arXiv:2407.01463, 2024. [Online]. Available: https://arxiv.org/abs/2407.01463

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Información adicional (opcional):

Contexto del problema:	Proyecto con potencial de innovación y divulgación científica en múltiples revistas y conferencias, como, por ejemplo: • Rank: B, 28th ACM International Conference on Multimodal Interaction (Napoli 5-9-2026), https://icmi.acm.org/2026/important-dates/ • Class: C, ICMLAI International Conference on Machine Learning and Applications (Madrid 18-05-2026). https://ai.pagesconferences.org/ • Subclass: A+, ICAART International Conference on Agents and Artificial Intelligence, (Valleta, 23-2-2027), https://icaart.scitevents.org/ImportantDates.aspx
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	• Redes neuronales • Modelos fundacionales • Modelos de lenguaje de gran tamaño • Representaciones vectoriales (Embeddings) • Generación aumentada por recuperación (RAG) • Búsqueda por similitud • Modo Agente y Contexto
+ Información	• Bases de datos con operaciones vectoriales pgVector, Milvus, etc. • Evaluación de respuestas de RAG mediante otros modelos de lenguaje • Inteligencia Artifical Explicable • Métricas enfocadas en la recuperación de información • Reglamento de Inteligencia Artificial de la Unión Europea (AI Act) • Estándares para sistemas de Inteligencia Artificial, como ISO 42000 y otros.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Carlos Rubert Escuder**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Banco de pruebas y marco de evaluación integral para modelos de lenguaje compactos en generación de materiales adaptados: calidad pedagógica, accesibilidad cognitiva y riesgos

Descripción del problema a abordar

Este TFM aborda una carencia habitual en proyectos con modelos generativos: se tiende a evaluar el entrenamiento (pérdida, métricas internas) sin disponer de un marco externo que permita justificar, con evidencias, si las salidas son adecuadas para su uso educativo. El problema se concreta en diseñar un banco de pruebas reproducible y un protocolo de evaluación que permita comparar modelos de lenguaje compactos (y sus variantes tras especialización) en tareas de adaptación de materiales para ESO y, de forma específica, para necesidades de apoyo educativo.

La evaluación se formula como un sistema multicriterio que debe medir, al menos, cuatro dimensiones: (1) fidelidad al contenido de partida (evitar errores conceptuales y omisiones relevantes), (2) claridad y adecuación al nivel, (3) accesibilidad cognitiva (estructura, segmentación de ideas, apoyo léxico), y (4) riesgos y seguridad de uso (afirmaciones no sustentadas, sesgos, contenido inadecuado).

El resultado esperado es un conjunto de artefactos reutilizables: conjunto de prueba congelado, rúbricas, scripts de evaluación automática, informe de errores y recomendaciones de uso.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Información adicional (opcional):

Contexto del problema:	En el contexto de un copilot docente, la adopción depende de la confianza: el profesorado necesita evidencias para decidir si una salida se puede usar, cuánto tiempo requiere revisarla y qué tipos de fallos son frecuentes. Por ello, este TFM encaja directamente con la exigencia del máster de estimar y evaluar el rendimiento de un sistema según técnicas, datos y contexto de ejecución, de asegurar rigor y control de errores y de atender requisitos de seguridad, rendimiento e interacción con humanos. Además, por su naturaleza aplicada, el trabajo obliga a integrar consideraciones éticas y sociales cuando la información es limitada y a comunicar conclusiones de forma clara a públicos especializados y no especializados. Además, exige una interpretación rigurosa de resultados, la lectura crítica de métricas y la explicación de límites y condiciones de uso, Por último, requiere del análisis del contexto real considerando estándares éticos, sociales y legales. Posibilidad de desarrollar un artículo científico.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	1. Diseño experimental y replicabilidad (núcleo metodológico) • Definición de variables controladas: mismo conjunto de entradas, mismas condiciones de generación (temperatura, longitud máxima, etc.), mismo protocolo de evaluación para todos los modelos comparados. • Construcción de particiones sin fugas (train/valid/test), y fijación de un test congelado que no se modifica una vez definido. • Ablaciones: análisis de cómo cambian los resultados al variar una sola decisión (modelo base, adaptación, parámetros de generación, presencia de glosario, estructura). 2. Evaluación automática orientada a educación (sin sustituir la evaluación humana) • Métricas de simplificación y reescritura: SARI como métrica específica de simplificación, y medidas complementarias de similitud semántica (p. ej., BERTScore) para vigilar preservación de significado. • Comprobación de restricciones: longitud media de frase, número de ideas por párrafo, presencia de definiciones breves cuando proceda, y preservación de términos clave del temario (listas de control por unidad didáctica). • Señales de consistencia/factualidad: detección de posibles afirmaciones no sustentadas mediante contraste con el texto fuente o con un material de referencia. 3. Evaluación humana estructurada (rúbrica docente) • Definición de criterios claros y observables: fidelidad, claridad, adecuación a ESO, coherencia, utilidad didáctica, y tiempo estimado de revisión.

	• Muestreo estratificado: por tema, dificultad y tipo de texto (definiciones, explicaciones de procesos, narraciones históricas, etc.). • Medición de acuerdo entre evaluadores (Cohen's kappa o Krippendorff's alpha, según el diseño), y análisis de desacuerdos para refinar rúbrica y criterios. 4. Análisis de riesgos y documentación de límites • Taxonomía de errores: alucinación (datos inventados), omisión (falta de ideas esenciales), distorsión por simplificación excesiva, ambigüedad, sesgos, y contenido inadecuado para el aula. • Procedimiento de mitigación: reglas de formato, listas de términos obligatorios, avisos al usuario cuando falte respaldo, y recomendación de revisión docente en casos de mayor riesgo. 5. Herramientas y entorno de trabajo (implementación) • Python con un pipeline reproducible (conda y versionado de dependencias). • Librerías típicas: transformers (inferencias comparables), evaluate o scripts propios para métricas, bert-score, pandas/numpy para análisis, scikit-learn para medidas de acuerdo, y herramientas de anotación (por ejemplo, Label Studio) si se realiza evaluación humana. • Registro de experimentos: configuración por corrida (modelo, parámetros, semilla), resultados por ejemplo y por lote, y generación de informes (gráficas y ejemplos representativos).
+ Información	Bibliografía Inicial: • Xu, W., Napoles, C., Pavlick, E., Chen, Q., & Callison-Burch, C. (2016). *Optimizing Statistical Machine Translation for Text Simplification*. Transactions of the ACL. • Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2019). *BERTScore: Evaluating Text Generation with BERT*. arXiv:1904.09675. • Manakul, P., Liusie, A., & Gales, M. (2023). *SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models*. arXiv:2303.08896. • Liang, P., Bommasani, R., Lee, T., et al. (2022). *Holistic Evaluation of Language Models (HELM)*. arXiv:2211.09110. • Artstein, R., & Poesio, M. (2008). *Inter-Coder Agreement for Computational Linguistics*. Computational Linguistics, 34(4). • Krippendorff, K. (2011). *Computing Krippendorff's Alpha-Reliability*. Departmental Papers (ASC), University of Pennsylvania. • Flesch, R. (1948). *A New Readability Yardstick*. Journal of Applied Psychology.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Raúl Homero Llasag Rosero**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Métodos de agregación federada basados en similitud aplicados al fraude financiero

Descripción del problema a abordar

Con el crecimiento de los sistemas financieros digitales, la privacidad y la seguridad de los datos se han vuelto una preocupación para muchas instituciones [1]. A pesar de que muchos modelos de inteligencia artificial han demostrados ser efectivos en la detección de fraudes, usualmente comprometen el uso de los datos del usuario o requieren la centralización de los datos en una única fuente. El aprendizaje federado, un paradigma de aprendizaje de máquina distribuido y enfocado en la privacidad de los datos, ha permitido a distintas entidades compartir conocimiento de una manera privada de sus modelos de predicción para que puedan mejorar su capacidad predictiva [2]. Las soluciones federadas en su gran mayoría han adoptado técnicas de compartimiento de datos basados en la agregación de parámetros, limitando en gran parte a la configuración de soluciones federadas en que todas las partes predicen con un mismo mapa de datos de entrada la predicción de fraudes [3-4]. Técnicas de agregación de conocimiento basadas en la similitud de los datos han permitido compartir conocimiento entre partes permitiendo que sus conjuntos de datos varíen parcialmente en el mapa de datos de entrada de sus modelos [5]. Lamentablemente, estas técnicas han sido poco exploradas en el ámbito de la detección de fraudes donde múltiples entidades, un problema donde usualmente las entidades financieras difieren en el mapa de entrada de datos de sus modelos predictivos. Este proyecto pretende comparar la capacidad de las técnicas de compartición de conocimiento con otras técnicas existentes en el contexto de detección de fraude financiero.

Bibliografía

- [1] T. Ahmed, M. J. Ferdus, R. Parvez, M. A. H. Lachchu, S. Arefin, and M. Ahsan, "Financial Fraud Detection using Synthetic Dataset: An Analysis of Machine Learning Algorithms," in *Proc. 2025 IEEE Int. Conf. Electro Information Technology (eIT)*, 2025, pp. 406-411, doi: 10.1109/eIT64391.2025.11103694.
- [2] M. Emmanuel, "Federated Learning for Privacy-Preserving Financial Fraud Detection," SSRN, May 20, 2025. [Online]. Available: https://ssrn.com/abstract=5399668 doi: 10.2139/ssrn.5399668
- [3] C. H. Kennedy, A. Hilal, and M. Momeni, "The Role of Federated Learning in Improving Financial Security: A Survey," arXiv preprint arXiv:2510.14991, 2025. [Online]. Available: https://arxiv.org/abs/2510.14991

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

- [4] M. Emmanuel, "Federated Learning for Privacy-Preserving Financial Fraud Detection," SSRN, May 20, 2025. [Online]. Available: https://ssrn.com/abstract=5399668 doi: 10.2139/ssrn.5399668
- [5] R. Llasag Rosero, C. Silva, B. Ribeiro, M. Albisser, M. Brutsche, and M. Arias Chao, "Label synchronization strategies for hybrid federated learning," Reliability Engineering & System Safety, vol. 256, p. 110751, 2025. doi: 10.1016/j.ress.2024.110751.

Información adicional (opcional):

Contexto del problema:	Proyecto con potencial de innovación y divulgación científica en múltiples revistas y conferencias, como, por ejemplo: • FLTA- La 4ta Conferencia Internacional en Tecnologías de Aprendizaje Federado y sus Aplicaciones (Paris, 27-1- 2026), https://flta-conference.org/flta-2026/ • IJCAI-ECAI, Taller Internacional en Aprendizaje Federado en la Era de Modelos Fundacionales, en Conjunto con La Conferencia Internacional en Inteligencia Artificial (Bremen, 16-8-2026) , https://federated-learning.org/fl@fm-ijcai-2026/
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	• Redes neuronales • Aprendizaje supervicionado • Arquitectura de Computadores • Computación en el borde (Edge Computing) • Aprendizaje Federado (Federated Learning) • Finanzas y Negocios
+ Información	• Métricas enfocadas en la recuperación de información • Reglamento de Inteligencia Artificial de la Unión Europea (AI Act) • Estándares para sistemas de Inteligencia Artificial, como ISO 42000 y otros. • Algoritmos de aprendizaje particionado en diferentes topologías de particionamiento de datos.

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ruth Palmero Sánchez**
Codirector[1]:	**Sergio Mauricio Martinez Monterrubio**

La propuesta se adapta a TFE grupal	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta (Máximo 20 palabras).

Hacia una IA más sostenible: Edge AI

Descripción del problema a abordar (Máximo 300 palabras).

La expansión acelerada de la inteligencia artificial está generando un incremento sin precedentes en el consumo energético global. En la actualidad, la IA ya representa alrededor del 2% del consumo eléctrico mundial, con datos que muestran que los centros de datos asociados generan entre 2,5% y 3,7% de las emisiones globales de gases de efecto invernadero, superando incluso al sector de la aviación.

Las proyecciones para los próximos años son aún más preocupantes: para 2026, la IA podría consumir casi la mitad de toda la electricidad destinada a centros de datos a nivel global, y para 2030 su demanda podría más que duplicarse hasta alcanzar cerca del 3% del consumo eléctrico mundial. En este contexto, se hace necesario investigar enfoques que permitan **reducir la huella ambiental del entrenamiento de modelos de IA** sin comprometer la calidad de los resultados.

El campo de **Edge AI eficiente** se centra en desarrollar y ejecutar modelos de inteligencia artificial directamente en dispositivos de bajo consumo, como **Raspberry Pi**, **ESP32**, microcontroladores, sensores IoT o incluso teléfonos móviles. A diferencia de los sistemas tradicionales que dependen de centros de datos intensivos en energía para la inferencia, el *edge computing* desplaza el procesamiento hacia el propio dispositivo, reduciendo la necesidad de enviar datos a la nube y evitando el uso continuo de grandes infraestructuras de cómputo.

Este enfoque tiene un impacto directo en la **sostenibilidad medioambiental**. Por un lado, disminuye el consumo energético global al evitar la ejecución de modelos en servidores de alta potencia, responsables de una parte significativa de las emisiones y del gasto energético de la IA moderna. Por otro lado, reduce el tráfico de datos y, por tanto, la energía asociada a las comunicaciones, lo que es especialmente relevante en aplicaciones con miles o millones de dispositivos IoT. Además, obliga a diseñar modelos ligeros y optimizados,

[1] Únicamente en el caso de doctorando y que no sea pdi de la universidad.

fomentando el uso de técnicas que minimizan el cómputo y la memoria —como la cuantización, la poda o el uso de arquitecturas eficientes—, todas ellas alineadas con los principios del *Green Software*.

El proyecto que se propone consiste en:

1. Desarrollar un pipeline automatizado que permita reproducir el proceso completo: entrenamiento, optimización, despliegue en dispositivo y medición energética, generando un conjunto de métricas normalizadas para evaluar la sostenibilidad del modelo.
   - Scripts reproducibles en Python o Bash.
   - Automatización del despliegue vía SSH, ADB o frameworks de Edge Impulse.
   - Registro centralizado de energía, latencia y métricas de calidad del modelo.
2. Analizar el impacto de ejecutar IA localmente frente a enviar los datos a la nube, comparando la energía total utilizada por inferencia en ambos escenarios para cuantificar el beneficio ambiental del enfoque Edge AI.
   - Medición del consumo energético en inferencias locales.
   - Estimación del coste energético de transferir datos a la nube (energía en redes + energía del servidor).
   - Determinar el ahorro energético total aportado por Edge AI en un caso de uso concreto.

Bibliografía:

Palmero, R. (05 de marzo de 2025). ¿Qué es el Green Software? https://www.adrformacion.com/blog/que_es_el_green_software.html

Currie, A., Hsu, S., & Bergman, S. (2024). Building green software: A sustainable approach to software development and operations. O'Reilly Media

Husom, E. J., Goknil, A., Astekin, M., Shar, L. K., Kåsen, A., Sen, S., Mithassel, B. A., & Soylu, A. (2025). Sustainable LLM inference for Edge AI: Evaluating quantized LLMs for energy efficiency, output accuracy, and inference latency. arXiv:2504.03360. https://doi.org/10.48550/arXiv.2504.03360

Bhagavathula, V. K., Gao, X., Zhou, Y., Hodhod, R., & Wang, L. (2025). Energy-efficiency modeling for AI applications on edge computing. In Internet Computing and IoT and Embedded Systems, Cyber physical Systems, and Applications (pp. 164–177). Springer.

Husom, E. J., Goknil, A., Astekin, M., Shar, L. K., Kåsen, A., Sen, S., Mithassel, B. A., & Soylu, A. (2025). Sustainable LLM inference for Edge AI: Evaluating quantized LLMs for energy efficiency, output accuracy, and inference latency. ACM Transactions on Internet of Things, 6(4). https://doi.org/10.1145/3767742

Xie, Y., & Fang, Q. (2025). An energy aware generative AI edge inference framework for low-power IoT devices. Electronics, 14(20), 4086. https://doi.org/10.3390/electronics14204086

Husom, E. J., Goknil, A., Astekin, M., Shar, L. K., Kåsen, A., Sen, S., Mithassel, B. A., & Soylu, A. (2025). Sustainable LLM inference for Edge AI: Evaluating quantized LLMs for energy efficiency, output accuracy, and inference latency. arXiv preprint arXiv:2504.03360.

Información adicional (opcional):

Contexto del problema (Máximo 100 palabras):	Debería de ser posible hacer un proyecto con artefacto funcional sin necesidad de supercomputadores, porque el aprendizaje federado se presta a entornos simulados y experimentos de pequeña escala
Conceptos que el alumno debe dominar (ítems)	El alumnado deberá de aprender conceptos sobre Green Software y Green AI, de ahí que la primera tarea será llevar a cabo un SotA, dado que no será común que los comprendan. Edge AI eficiente es una línea altamente viable y práctica, ya que permite implementar prototipos funcionales utilizando hardware de muy bajo coste. Existen múltiples frameworks accesibles —TensorFlow Lite, PyTorch Mobile, Edge Impulse, MicroTensor— que facilitan la conversión de modelos a versiones optimizadas, así como herramientas para medir latencia, consumo energético y rendimiento. Esto permite al estudiante desarrollar un modelo real, desplegarlo en un dispositivo físico, medir su eficiencia y demostrar con datos cómo la IA puede ser más sostenible mediante el uso de técnicas de edge computing. En conjunto, Edge AI eficiente representa una vía práctica, didáctica y con alto valor social y tecnológico para generar IA sostenible, reduciendo el impacto ambiental al tiempo que se abren oportunidades para aplicaciones distribuidas, autónomas y de bajo consumo energético.
+ Información	Dado que el enfoque es genérico, se puede proponer a varios grupos, dado que le pueden dar un contexto diferente. El proyecto se podría incorporar como herramienta Open Source de la Green Software Foundation y ser diseminada por dicha organización.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ruth Palmero Sánchez**
Codirector[1]:	**Sergio Mauricio Martinez Monterrubio**

La propuesta se adapta a TFE grupal	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta (Máximo 20 palabras).

Hacia una IA más sostenible: Compresión de modelos

Descripción del problema a abordar (Máximo 300 palabras).

La expansión acelerada de la inteligencia artificial está generando un incremento sin precedentes en el consumo energético global. En la actualidad, la IA ya representa alrededor del 2% del consumo eléctrico mundial, con datos que muestran que los centros de datos asociados generan entre 2,5% y 3,7% de las emisiones globales de gases de efecto invernadero, superando incluso al sector de la aviación.

Las proyecciones para los próximos años son aún más preocupantes: para 2026, la IA podría consumir casi la mitad de toda la electricidad destinada a centros de datos a nivel global, y para 2030 su demanda podría más que duplicarse hasta alcanzar cerca del 3% del consumo eléctrico mundial. En este contexto, se hace necesario investigar enfoques que permitan **reducir la huella ambiental del entrenamiento de modelos de IA** sin comprometer la calidad de los resultados.

En este contexto, el campo de Model Compression & Efficient AI se centra en desarrollar técnicas que reduzcan el tamaño, el cómputo y los recursos necesarios para ejecutar modelos, manteniendo una precisión comparable a la de sus versiones originales. Estas técnicas incluyen métodos como pruning (eliminación de parámetros innecesarios), quantization (reducción de la precisión numérica), knowledge distillation (transferencia del conocimiento de un modelo grande a uno más pequeño), y low-rank factorization, entre otras.

El objetivo común de todas ellas es construir modelos más ligeros, más rápidos y menos exigentes desde el punto de vista computacional. Este enfoque es clave para la sostenibilidad porque disminuye directamente el uso de CPU, GPU y memoria, lo que a su vez reduce el consumo energético y la huella de carbono asociada al procesamiento. Además, los modelos comprimidos permiten ejecutar la IA en dispositivos de bajo consumo —

[1] Únicamente en el caso de doctorando y que no sea pdi de la universidad.

como móviles, sensores IoT o microcontroladores— evitando la necesidad de depender de centros de datos de gran tamaño, cuya demanda energética es considerable.

Desde la perspectiva medioambiental, **Model Compression & Efficient AI** ofrece un doble beneficio: por un lado, reduce los recursos necesarios para entrenar modelos complejos, y por otro, disminuye el coste energético durante la inferencia, que es la fase más repetida y acumulativa en sistemas de IA desplegados a gran escala. Esto lo convierte en un área especialmente alineada con los principios del Green Software, donde se promueve el diseño de sistemas digitales eficientes y respetuosos con el entorno.

El proyecto que se propone consiste en:

1. Implementar y evaluar técnicas de compresión de modelos (pruning, quantization y distillation) para reducir el consumo energético durante la inferencia sin degradar significativamente la precisión.

Este objetivo implica:

- aplicar distintos métodos de compresión sobre un mismo modelo base,
- medir el impacto en parámetros, FLOPs y latencia,
- cuantificar el consumo energético usando herramientas como CodeCarbon o CarbonTracker,
- analizar el compromiso entre eficiencia y rendimiento del modelo.

Bibliografía:

Palmero, R. (05 de marzo de 2025). ¿Qué es el Green Software? https://www.adrformacion.com/blog/que_es_el_green_software.html

Currie, A., Hsu, S., & Bergman, S. (2024). Building green software: A sustainable approach to software development and operations. O'Reilly Media

Paula, E., Soni, J., Upadhyay, H., & Lagos, L. (2025). Comparative analysis of model compression techniques for achieving carbon efficient AI. Scientific Reports. https://www.nature.com/articles/s41598-025-07821-w.pdf

Vilar Dantas, P., da Silva Jr., W. S., Cordeiro, L. C., & Carvalho, C. B. (2024). A comprehensive review of model compression techniques in machine learning. Applied Intelligence, 54, 11804–11844. https://doi.org/10.1007/s10489-024-05747-w

Chaurasiya, R., & Sharma, V. (2025). Energy-efficient deep learning via compression: Green AI. International Journal of Scientific Research & Engineering Trends, 11(3). https://ijsret.com/wp-content/uploads/IJSRET_V11_issue3_1143.pdf

Stow, M., & Stewart, A. A. (2025). Reducing carbon footprint of machine learning through model compression and pruning. International Journal of Innovative Science and Research Technology, 10(8), 1479–1503. https://doi.org/10.38124/ijisrt/25aug970

Mei, L., & Stamp, M. (2025). Energy considerations for large pretrained neural networks. arXiv:2506.01311. https://arxiv.org/pdf/2506.01311

Información adicional (opcional):

Contexto del problema (Máximo 100 palabras):	El proyecto se podría incorporar como herramienta Open Source de la Green Software Foundation y ser diseminada por dicha organización.
Conceptos que el alumno debe dominar (ítems)	El alumnado deberá de aprender conceptos sobre Green Software y Green AI, de ahí que la primera tarea sea la de llevar a cabo un SotA, dado que no será común que los comprendan.
+ Información	Dado que el enfoque es genérico, se puede proponer a varios grupos, dado que le pueden dar un contexto diferente. Finalmente, para un Trabajo de Fin de Máster, esta línea es especialmente atractiva porque permite desarrollar experimentos reales y reproducibles con recursos modestos. Es posible entrenar y comprimir modelos pequeños en un portátil, medir su consumo energético con herramientas open-source y demostrar mejoras cuantificables en eficiencia sin necesidad de acceso a grandes infraestructuras. Esto convierte a *Model Compression & Efficient AI* en una opción sólida, viable y con impacto real para estudiar cómo la IA puede evolucionar hacia prácticas más sostenibles.

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**José Manuel Bernal de Lázaro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Implementación de enfoques data-driven para la detección de fallos en procesos industriales

Descripción del problema a abordar

Se desarrollan e implementan métodos basados en datos para la detección temprana de fallos en procesos industriales, utilizando técnicas de aprendizaje automático y análisis estadístico. Estos enfoques permiten identificar patrones anómalos en variables de proceso y mejorar las estrategias de mantenimiento predictivo.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Familiarizarse con los procesos físicos, y datos Conocimientos básicos de álgebra matricial Manejo de lenguajes de programación Python/Matlab

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ivón Oristela Benítez González**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Modelado híbrido basado en inteligencia artificial y conocimiento físico para la predicción y optimización de sistemas energéticos complejos

Descripción del problema a abordar

El presente trabajo propone el desarrollo de un enfoque de modelado híbrido que combina inteligencia artificial y conocimiento físico para la representación y análisis de sistemas energéticos complejos. Este enfoque integra modelos matemáticos basados en principios físicos con técnicas de aprendizaje automático, permitiendo capturar tanto la dinámica del sistema como los patrones presentes en los datos.

El modelo resultante estará orientado a mejorar la capacidad de predicción y a optimizar la operación de los sistemas energéticos, contribuyendo a una mayor eficiencia, confiabilidad y sostenibilidad. Esta aproximación se alinea con las tendencias actuales en inteligencia artificial aplicada a la energía, facilitando la toma de decisiones informadas en entornos complejos y dinámicos.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Fundamentos de modelado matemático y sistemas dinámicos, especialmente en sistemas energéticos no lineales. Técnicas de inteligencia artificial y machine learning (regresión, redes neuronales, modelos híbridos). Conocimientos de sistemas energéticos (renovables, redes eléctricas, optimización energética). Manejo de Python y herramientas científicas (NumPy, SciPy, scikit-learn, TensorFlow/PyTorch) para simulación y análisis.
+ Información	

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ruth Palmero Sánchez**
Codirector[1]:	**Sergio Mauricio Martinez Monterrubio**

La propuesta se adapta a TFE grupal	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta (Máximo 20 palabras).

Hacia una IA más sostenible: Evaluación del Federated Learning como estrategia de Green Software

Descripción del problema a abordar (Máximo 300 palabras).

La expansión acelerada de la inteligencia artificial está generando un incremento sin precedentes en el consumo energético global. En la actualidad, la IA ya representa alrededor del 2% del consumo eléctrico mundial, con datos que muestran que los centros de datos asociados generan entre 2,5% y 3,7% de las emisiones globales de gases de efecto invernadero, superando incluso al sector de la aviación.

Las proyecciones para los próximos años son aún más preocupantes: para 2026, la IA podría consumir casi la mitad de toda la electricidad destinada a centros de datos a nivel global, y para 2030 su demanda podría más que duplicarse hasta alcanzar cerca del 3% del consumo eléctrico mundial. En este contexto, se hace necesario investigar enfoques que permitan **reducir la huella ambiental del entrenamiento de modelos de IA** sin comprometer la calidad de los resultados.

El *federated learning* surge como una alternativa prometedora al evitar la centralización de datos y distribuir el entrenamiento entre múltiples nodos, disminuyendo así la necesidad de grandes infraestructuras centralizadas y reduciendo el movimiento de datos. Sin embargo, su impacto real sobre la sostenibilidad energética no está completamente cuantificado ni se conocen con precisión qué configuraciones, estrategias de agregación o patrones de comunicación permiten maximizar su eficiencia ambiental.

El problema que se plantea en este proyecto es, por tanto, **analizar y evaluar en qué medida el aprendizaje federado puede contribuir a reducir el consumo energético asociado al entrenamiento de modelos de IA**, identificando las condiciones y técnicas que permiten optimizar su desempeño desde una perspectiva de sostenibilidad. Esto incluye comparar entrenamiento centralizado y federado, medir el impacto energético de

[1] Únicamente en el caso de doctorando y que no sea pdi de la universidad.

diferentes configuraciones y proponer recomendaciones prácticas que permitan avanzar hacia modelos de IA más eficientes y respetuosos con el medio ambiente.

El proyecto que se propone consiste en:

1. Evaluar en qué medida el *federated learning* puede reducir el impacto medioambiental del entrenamiento de modelos de IA, identificando configuraciones, técnicas y estrategias que permitan optimizar su sostenibilidad sin comprometer el rendimiento del modelo.
2. **Diseñar y desarrollar un prototipo funcional de sistema de aprendizaje federado**, simulando múltiples nodos distribuidos para evaluar su comportamiento energético frente a un entrenamiento centralizado.

Bibliografía:

Palmero, R. (05 de marzo de 2025). ¿Qué es el Green Software? https://www.adrformacion.com/blog/que_es_el_green_software.html

Currie, A., Hsu, S., & Bergman, S. (2024). Building green software: A sustainable approach to software development and operations. O'Reilly Media

McMahan, B., Moore, E., Ramage, D., Hampson, S., & Aguera y Arcas, B. (2017). *Communication-efficient learning of deep networks from decentralized data*. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics* (pp. 1273–1282). PMLR. [proceeding....mlr.press]

Bonawitz, K., Eichner, H., Grieskamp, W., Huba, D., Ingerman, A., Ivanov, V., Kiddon, C., Konečný, J., Mazzocchi, S., McMahan, H. B., Van Overveldt, T., Petrou, D., Ramage, D., & Roselander, J. (2019). *Towards federated learning at scale: System design*. *arXiv preprint* arXiv:1902.01046. [arxiv.org]

Kairouz, P., McMahan, H. B., Avent, B., Bellet, A., Bennis, M., Bhagoji, A. N., Bonawitz, K., Charles, Z., Cormode, G., Cummings, R., D'Oliveira, R. G. L., Eichner, H., El Rouayheb, S., Evans, D., Gardner, J., Garrett, Z., Gascón, A., Ghazi, B., Gibbons, P. B., ... Zhao, S. (2021). *Advances and open problems in federated learning*. *Foundations and Trends in Machine Learning, 14*(1–2), 1–210. https://doi.org/10.1561/2200000083

Thakur, D., Guzzo, A., Fortino, G., & Piccialli, F. (2024). *Green Federated Learning: A new era of green aware AI*. arXiv preprint arXiv:2409.12626.

Kim, M., & Saad, W. (2024). *Toward green federated learning*. In *Handbook of Trustworthy Federated Learning* (pp. 409–428). Springer. https://doi.org/10.1007/978-3-031-58923-2_14

Qiu, X., Parcollet, T., Fernandez-Marques, J., Gusmao, P. P. B., Gao, Y., Beutel, D. J., Topal, T., Mathur, A., & Lane, N. D. (2023). *A first look into the carbon footprint of federated learning*. *Journal of Machine Learning Research, 24*(129), 1–23. [jmlr.org]

S. Iftikhar, S. H. Alsamhi and S. Davy, "Enhancing Sustainability in LLM Training: Leveraging Federated Learning and Parameter-Efficient Fine-Tuning," in IEEE Transactions on Sustainable Computing, vol. 10, no. 6, pp. 1158-1172, Nov.-Dec. 2025, doi: 10.1109/TSUSC.2025.3592043.

Información adicional (opcional):

Contexto del problema (Máximo 100 palabras):	Debería de ser posible hacer un proyecto con artefacto funcional sin necesidad de supercomputadores, porque el aprendizaje federado se presta a entornos simulados y experimentos de pequeña escala
Conceptos que el alumno debe dominar (ítems)	El alumnado deberá de aprender conceptos sobre Green Software y Green AI, de ahí que la primera tarea será llevar a cabo un SotA, dado que no será común que los comprendan. Para llevar a cabo el proyecto, se utilizarán frameworks específicos de FL (TensorFlow Federated (TFF), PySyft (OpenMined), Flower (FLWR)) o herramientas para medir uso energético (CodeCarbon, CarbonTracker). Si no se tienen conocimientos, se deberán de adquirir ..
+ Información	Dado que el enfoque es genérico, se puede proponer a varios grupos, dado que le pueden dar un contexto diferente. El proyecto se podría incorporar como herramienta Open Source de la Green Software Foundation y ser diseminada por dicha organización.

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ivón Oristela Benítez González**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

"Framework basado en edge computing e inteligencia artificial para la optimización energética y detección de anomalías en entornos industriales conectados"

Descripción del problema a abordar

El presente trabajo propone el desarrollo de un framework basado en tecnologías de *edge computing* e inteligencia artificial para la optimización energética y la detección temprana de anomalías en entornos industriales conectados. El enfoque combina la adquisición de datos a través de dispositivos IoT con su procesamiento local en el borde de la red, permitiendo una respuesta más rápida y eficiente frente a variaciones operativas o fallos incipientes.

Mediante el uso de algoritmos de aprendizaje automático, el sistema será capaz de identificar patrones anómalos en el consumo energético y en el comportamiento de los equipos, contribuyendo a mejorar la eficiencia operativa, reducir costos y aumentar la confiabilidad del sistema industrial. Este enfoque se alinea con los principios de la Industria 4.0, facilitando la toma de decisiones en tiempo real y la gestión inteligente de los recursos energéticos.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	IoT y edge computing, incluyendo adquisición y procesamiento de datos en tiempo real. Fundamentos de inteligencia artificial y machine learning (detección de anomalías, modelos predictivos). Conocimientos básicos de sistemas energéticos industriales y eficiencia energética. Manejo de Python y librerías de análisis de datos (pandas, scikit-learn) junto con técnicas de preprocesamiento y visualización.
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ivón Oristela Benítez González**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Desarrollo de un gemelo digital inteligente basado en IoT y aprendizaje automático para el mantenimiento predictivo en sistemas industriales

Descripción del problema a abordar

El presente trabajo propone el desarrollo de un gemelo digital inteligente para sistemas industriales, integrando tecnologías IoT y técnicas de aprendizaje automático con el fin de mejorar el mantenimiento predictivo. El sistema se basará en la adquisición de datos operacionales mediante sensores conectados, los cuales alimentarán un modelo virtual capaz de replicar el comportamiento del activo físico en tiempo casi real.

A través del uso de algoritmos de machine learning, el gemelo digital permitirá identificar patrones de degradación, detectar fallos incipientes y predecir posibles fallos futuros. Esto contribuirá a optimizar las estrategias de mantenimiento, reducir tiempos de inactividad y mejorar la confiabilidad y eficiencia operativa, en línea con los principios de la Industria 4.0.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Fundamentos de gemelos digitales e IoT, incluyendo sensorización, adquisición de datos y comunicación entre sistemas físicos y virtuales. Conocimientos de machine learning aplicado a mantenimiento predictivo (detección de anomalías y predicción de fallos). Conceptos de confiabilidad y mantenimiento industrial (MTBF, MTTR, mantenimiento predictivo). Manejo de Python y herramientas de análisis de datos (pandas, scikit-learn, visualización).
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**José Manuel Bernal de Lázaro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Análisis comparativo de técnicas de inteligencia computacional aplicadas al diagnóstico de aerogeneradores

Descripción del problema a abordar

Se realiza un estudio comparativo de diferentes técnicas de inteligencia computacional, como redes neuronales, máquinas de soporte vectorial y métodos evolutivos, para el diagnóstico de fallos en aerogeneradores. El análisis evalúa su precisión, robustez y capacidad de generalización en condiciones reales de operación.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Familiarizarse con los procesos físicos, y datos correspondientes Conocimientos básicos de álgebra matricial Manejo de lenguajes de programación Python/Matlab
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**José Manuel Bernal de Lázaro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Inspección y reconocimiento de anomalías en paneles fotovoltaicos utilizando imágenes RGB

Descripción del problema a abordar

Se desarrollan métodos de visión por computadora para la detección automática de anomalías en paneles fotovoltaicos a partir de imágenes RGB. Mediante técnicas de procesamiento de imágenes y aprendizaje profundo, se busca identificar defectos estructurales o degradación que puedan afectar el rendimiento del sistema.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Familiarizarse con los procesos físicos, y datos correspondientes Conocimientos básicos de álgebra matricial Manejo de lenguajes de programación Python/Matlab
+ Información	

unir LA UNIVERSIDAD EN INTERNET

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Ivón Oristela Benítez González**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Modelado de sistemas industriales mediante inteligencia artificial informada por la física y datos IoT para aplicaciones en optimización y control

Descripción del problema a abordar

El presente trabajo propone el desarrollo de un enfoque de modelado de sistemas industriales complejos mediante la integración de inteligencia artificial informada por la física y datos provenientes de entornos IoT. La metodología combina modelos físico-matemáticos con técnicas de aprendizaje automático, permitiendo capturar tanto el conocimiento del proceso como los patrones derivados de los datos en tiempo real.

El modelo resultante permitirá mejorar la predicción del comportamiento dinámico del sistema, así como optimizar su operación y facilitar estrategias de control más eficientes. Este enfoque contribuye a aumentar la precisión, interpretabilidad y robustez de los modelos, alineándose con los principios de la Industria 4.0 y la digitalización de sistemas industriales.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Fundamentos de modelado matemático de sistemas dinámicos y conocimiento de procesos industriales no lineales. Técnicas de inteligencia artificial y machine learning, especialmente modelos híbridos y redes neuronales informadas por la física (PINNs). Conceptos de IoT y adquisición de datos, incluyendo sensorización, comunicaciones y procesamiento de datos en tiempo real. Manejo de Python y herramientas científicas (NumPy, SciPy, TensorFlow/PyTorch) para simulación, análisis y optimización.
+ Información	

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**José Manuel Bernal de Lázaro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Análisis, monitoreo y predicción de condiciones críticas de operación en baterías de litio

Descripción del problema a abordar

Se proponen métodos de análisis y monitoreo para identificar condiciones críticas de operación en baterías de litio, utilizando modelos basados en datos y técnicas de aprendizaje automático. El objetivo es anticipar estados de degradación o riesgo operativo y contribuir a la gestión segura y eficiente de sistemas de almacenamiento de energía.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Familiarizarse con los procesos físicos, y datos correspondientes Conocimientos básicos de álgebra matricial Manejo de lenguajes de programación Python/Matlab
+ Información	

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**Sergio Cebollada López**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**Hasta tres integrantes**

Título orientativo de la propuesta

Desarrollo de materiales docentes innovadores para Formación Profesional

Descripción del problema a abordar

Con la nueva ley de Formación Profesional, surgen nuevos módulos (asignaturas docentes). Entre ellos, en la familia profesional de electricidad y electrónica aparece el módulo optativo PROGRAMACIÓN CON INTELIGENCIA ARTIFICIAL EN SISTEMAS ELECTRÓNICOS Y AUTOMÁTICOS. Dicho módulo tiene una duración de 100 horas de formación. Además, dado el tipo de alumnado que cursaría el módulo, los conocimientos deben partir desde una formación muy básica. Por tanto, existe un desafío desde el punto de vista de metodología docente en cuanto a cómo desarrollar la impartición.

Este trabajo plantea el desarrollo de materiales docentes que sean innovadores desde el punto de vista metodológico y que permitan optimizar el aprendizaje del alumnado de FP dados los conocimientos previos y las horas de docencia estipuladas.

Se plantean cuatro ítems a desarrollar:

- Materiales que soporten el aprendizaje previo a los conceptos de Inteligencia Artificial.
- Materiales que soporten el aprendizaje base de Machine Learning y Deep Learning.
- Materiales que soporten el aprendizaje base de otros campos de Inteligencia Artificial.
- Materiales que soporten actividades de ampliación desde el punto de vista del alumnado como de ampliación del currículo.

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

Información adicional (opcional):

Contexto del problema:	Posibilidad de desarrollar artículo científico o elaboración de libro docente.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Pyhton, Uso de Colab,, Raspberry PI, Linux, Machine Learning y Deep Learning
+ Información	Se aceptan líneas alternativas que guarden relación con el proyecto.

PROPUESTA DE TRABAJO FIN DE ESTUDIO

Director de la propuesta:	**José Manuel Bernal de Lázaro**
Codirector[1]:	
Número recomendado de integrantes del grupo:	**3**

Título orientativo de la propuesta

Aprendizaje ensemble para la detección de averías y fallos en procesos industriales

Descripción del problema a abordar

Se investigan métodos de aprendizaje ensemble que combinan múltiples modelos predictivos para mejorar la detección de averías en sistemas industriales. Este enfoque busca aumentar la precisión y la confiabilidad del diagnóstico mediante la integración de diferentes fuentes de información y modelos de aprendizaje.

Información adicional (opcional):

Contexto del problema:	Posibilidad de publicación de los resultados del TFM como artículo científico en evento o revista indexada.
Conceptos / herramientas / técnicas que es recomendable que el alumno domine	Familiarizarse con los procesos físicos, y datos correspondientes Conocimientos básicos de álgebra matricial Manejo de lenguajes de programación Python/Matlab

[1] Únicamente en el caso de doctorando o que no sea PDI de la universidad.

+ Información	