Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Inteligencia artificial

Modelado predictivo data-driven de trayectorias académicas en educación superior: Identificación de patrones socioeconómicos de vulnerabilidad para la mitigación del abandono estudiantil mediante un enfoque experimental.

Trabajo fin de estudio presentado por:	Nicole Valentina Chacón Sánchez
Tipo de trabajo:	Piloto Experimental
Director/a:	Javier Ricardo Luna Pineda
Fecha:	5/10/2026

1. Introducción

Esta Tesis de Fin de Máster aborda el abandono en la educación superior a través del aprendizaje automático y la ingeniería de datos. El estudio plantea una evaluación experimental comparativa entre dos enfoques distintos. Por un lado, analiza las reglas de negocio tradicionales que emplea la analítica institucional. Por otro lado, evalúa modelos de ensamble supervisados para anticipar el riesgo de deserción con datos de matrícula.

El trabajo utiliza una metodología reproducible y un marco de evaluación multidimensional. Este enfoque contempla tanto la equidad algorítmica como la interpretabilidad de los factores socioeconómicos. Con ello, se busca aportar evidencia sobre la viabilidad, la oportunidad de la alerta y las garantías éticas del sistema. El documento se organiza en capítulos bien definidos. Estos abarcan desde el contexto normativo y el estado del arte hasta el diseño del piloto, los resultados y sus implicaciones educativas.

1.1. Motivación

El abandono de los estudios superiores constituye un problema persistente de eficiencia y equidad para los sistemas educativos. En Colombia, el Sistema para la Prevención y Análisis de la Deserción en las Instituciones de Educación Superior (SPADIES) estimó para 2024 una deserción por cohorte promedio acumulada, calculada hasta el décimo semestre, del 22,61 % en el nivel universitario. Esta cifra es inferior al 27,99 % reportado en 2017 (Ministerio de Educación Nacional [MEN], 2026).

El fenómeno trasciende el contexto colombiano. Según la OCDE, en promedio solo el 43 % de los nuevos estudiantes de licenciatura se gradúa dentro de la duración teórica del programa. Sin embargo, ese porcentaje asciende al 70 % tres años después (OECD, 2025). Colombia se ubica por debajo de ese promedio, con alrededor del 16 % de graduación en el plazo teórico y cerca del 44 % tres años después (OECD, 2025). Estas cifras miden aspectos distintos y no son directamente comparables. A pesar de esto, coinciden en mostrar que una proporción considerable de estudiantes no culmina su trayectoria en el plazo esperado. Esto genera consecuencias académicas, económicas y sociales para los estudiantes, las instituciones y el Estado.

El abandono no se concibe en la literatura como un evento aislado, sino como el resultado de un proceso progresivo. El modelo clásico de Spady y Tinto lo vincula con la integración académica y social del estudiante dentro de la institución. Bajo este enfoque, una integración insuficiente incrementa la probabilidad de abandonar los estudios (Tinto, 1975, como se citó en Franz y Paetsch, 2023).

Esta idea se ha ampliado con el tiempo para dar más peso a las características individuales y de origen. Entre ellas destacan el género, el origen social, la condición migratoria y el apoyo institucional percibido. En esa línea, la evidencia muestra que la relación entre los factores socioeconómicos y la intención de abandonar no está mediada por completo por la integración y el compromiso (Hadjar et al., 2023). En conjunto, estos hallazgos respaldan una lectura multifactorial del fenómeno. Además, justifican la inclusión de variables socioeconómicas y de matrícula en los modelos predictivos.

Los indicadores oficiales de seguimiento, por su propia definición, identifican el abandono una vez consumado. En Colombia, el sistema SPADIES clasifica como desertor al estudiante que no se ha matriculado durante dos o más periodos consecutivos (MEN, 2026). Esto significa que la alerta llega cuando la interrupción de las actividades académicas ya ocurrió. Ante esta limitación, la investigación en minería de datos educativos ha recurrido al aprendizaje automático para estimar el riesgo de deserción de manera anticipada.

Una revisión sistemática realizada en 2020 analizó un cuerpo inicial de 1.275 artículos y seleccionó 21 estudios sobre educación presencial (Silva y Roman, 2021). Sus hallazgos mostraron que los árboles de decisión son la técnica más empleada, presentes en dos tercios de las investigaciones. A estos le siguen los métodos bayesianos y la regresión logística, mientras que los modelos de ensamble únicamente aparecen en el 28,5 % de los casos (Silva y Roman, 2021). Además, se observó que la exactitud predomina como la principal métrica de evaluación en la literatura.

Este panorama evidencia que la predicción temprana es un campo consolidado. Sin embargo, muestra un claro predominio de técnicas relativamente simples y de una métrica que no ofrece información suficiente cuando las clases están desbalanceadas (He y Garcia, 2009). Esta brecha metodológica deja un amplio margen para comparar modelos más robustos que utilicen métricas orientadas a la detección efectiva de los estudiantes en riesgo.

Más allá de la capacidad predictiva, el uso de estos modelos para orientar el apoyo institucional exige verificar que no produzcan resultados discriminatorios hacia grupos sensibles. Karimi-Haghighi et al. (2021) abordaron la predicción del abandono en estudios de grado desde la perspectiva de la equidad algorítmica. Para ello, utilizaron datos disponibles al momento de la matrícula, tales como la información demográfica, el centro de procedencia y la nota de admisión. Con estas variables, los autores obtuvieron modelos con un área bajo la curva ROC (AUC) de entre 0,77 y 0,78, los cuales fueron calibrados y evaluados por subgrupos mediante sus tasas de error (Karimi-Haghighi et al., 2021).

Los resultados de su estudio mostraron un desempeño relativamente equitativo en el AUC y en la tasa de falsos negativos entre los diferentes grupos. En otras palabras, se logró una probabilidad similar de no detectar el riesgo en aquellos estudiantes que efectivamente abandonan. Por su parte, las disparidades observadas en las tasas de falsos positivos se abordaron mediante un procedimiento de mitigación que no afectó la calibración del modelo (Karimi-Haghighi et al., 2021). Este antecedente demuestra que la detección temprana a partir de datos de matrícula es viable y que debe auditarse rigurosamente por subgrupos.

La relevancia de este trabajo es doble. En el plano social, anticipar qué estudiantes enfrentan un mayor riesgo de abandono permite orientar los apoyos institucionales hacia quienes más lo necesitan. Además, identificar las combinaciones específicas de condiciones socioeconómicas y de matrícula visibiliza las barreras reales que condicionan la continuidad de los estudios.

En el ámbito científico, el trabajo aporta una comparación experimental controlada entre dos enfoques distintos: un sistema tradicional basado en reglas y varios modelos de aprendizaje automático. Esta evaluación se realiza con métricas orientadas directamente a la detección de estudiantes en riesgo, analizando el desempeño por subgrupos para valorar su equidad algorítmica.

Finalmente, este tema se vincula de forma directa con la trayectoria previa de la autora. En investigaciones anteriores, se analizaron los indicadores de empleabilidad de egresados universitarios mediante técnicas de clasificación (Chacón Sánchez et al., 2020). Dicha experiencia motiva a extender el interés investigador desde la inserción laboral hacia los factores que garantizan la permanencia y el éxito de los estudiantes durante su etapa de formación.

1.2. Planteamiento del trabajo

De lo expuesto se desprende una necesidad concreta para las instituciones. Es imprescindible contar con evidencia comparativa y controlada sobre cuánto aporta el aprendizaje automático frente a los indicadores tradicionales de seguimiento. Asimismo, se requiere determinar en qué momento de la trayectoria del estudiante se puede anticipar el riesgo y si dicha anticipación resulta equitativa entre subgrupos.

Actualmente, los indicadores oficiales identifican el abandono una vez que la deserción ya ha ocurrido (MEN, 2026). Por otro lado, en los estudios predictivos revisados predominan los árboles de decisión individuales y el uso de la exactitud como métrica principal de evaluación (Silva y Roman, 2021). Sin embargo, la exactitud por sí sola resulta insuficiente cuando se trabaja con clases desbalanceadas (He y Garcia, 2009). Esta combinación de factores deja abierta una pregunta central sobre cuál es el valor añadido real de los modelos de aprendizaje automático en la detección temprana.

Para abordar esta necesidad, se propone un piloto experimental (Tipo 1) basado en el conjunto de datos de la UCI *Predict Students' Dropout and Academic Success* (Realinho et al., 2021). Este dataset reúne 4.424 registros de estudiantes de pregrado de una institución portuguesa, junto con 36 variables de matrícula y de rendimiento durante los dos primeros semestres.

El diseño del estudio compara dos enfoques principales. El caso base corresponde a un sistema tradicional guiado por reglas explícitas de rendimiento académico. Por su parte, el caso experimental emplea modelos de ensamble de aprendizaje automático. La detección del riesgo se evalúa en tres escenarios temporales distintos: utilizando únicamente datos de matrícula (E_1), agregando la información del primer semestre (E_2) y sumando el segundo semestre (E_3).

Dado que el caso base solo puede construirse a partir de E_2, la pregunta central del trabajo es si el modelo alimentado solo con datos de matrícula (E_1) logra anticipar la detección un semestre antes que la regla tradicional. Para ello, el abandono se formula como una clasificación binaria que contrasta a los estudiantes en deserción frente al resto. La evaluación prioriza la sensibilidad (*recall*) de los alumnos en riesgo, analizando además la

interpretabilidad de los patrones socioeconómicos y la equidad del desempeño por subgrupos.

La finalidad del trabajo es aportar evidencia reproducible que ayude a decidir si, cuándo y con qué garantías de equidad conviene incorporar modelos predictivos a los sistemas de alerta temprana, y que sirva de base para su posterior adaptación al contexto colombiano. Para ello, el código, los datos y las decisiones metodológicas se documentan en un repositorio con trazabilidad completa, aspecto que vincula el trabajo con la ingeniería de datos y la reproducibilidad de los experimentos. En consecuencia, el modelo no se plantea como una herramienta de decisión automática, sino como apoyo a la identificación de estudiantes que podrían requerir acompañamiento.

1.3. Estructura del trabajo

Para facilitar la lectura y comprensión del desarrollo de la investigación, la memoria se organiza en cinco capítulos. El Capítulo 1 (Introducción) presenta la motivación del estudio, el planteamiento del problema, la delimitación del alcance y los objetivos perseguidos. El Capítulo 2 (Contexto y estado del arte) delimita las definiciones normativas del abandono, analiza la literatura científica sobre la predicción del riesgo en educación superior y sintetiza el marco teórico de la equidad algorítmica. El Capítulo 3 (Objetivos concretos y metodología de trabajo) detalla el pipeline de ingeniería de datos, la caracterización del conjunto de datos, la construcción de los escenarios temporales, el caso base, los modelos de aprendizaje automático y el marco de evaluación. El Capítulo 4 (Desarrollo especifico de la contribución) expone la comparativa empírica del desempeño predictivo, el análisis de equidad por subgrupos y la interpretabilidad de las variables socioeconómicas. Finalmente, el Capítulo 5 (Conclusiones y trabajo futuro) resume los hallazgos principales, discute las limitaciones del estudio y propone líneas de investigación para su transferencia al contexto nacional.

2. Contexto y estado del arte

La formulación de un modelo predictivo para la permanencia estudiantil requiere una fundamentación teórica y técnica clara del dominio de aplicación. Este capítulo examina el panorama del abandono universitario, distinguiendo las particularidades conceptuales y operativas del contexto normativo e institucional frente a los criterios utilizados en conjuntos de datos abiertos de referencia internacional. Asimismo, se realiza una revisión sistemática del estado del arte enfocado en el uso de técnicas de minería de datos educativos, analizando las metodologías prevalentes, los algoritmos de clasificación empleados, las métricas de evaluación tradicionales y las nuevas aproximaciones orientadas a la equidad algorítmica y la descripción de los modelos. Finalmente, el capítulo sintetiza las principales brechas identificadas en la literatura actual, estableciendo el punto de unión con la propuesta experimental desarrollada en esta investigación.

2.1.Contexto del problema

La medición del abandono depende en gran medida de la definición adoptada en cada ámbito. Esta variación dificulta comparar las cifras de manera directa entre diferentes fuentes. En Colombia, el sistema SPADIES considera como desertor al estudiante que no se registra matriculado durante dos o más periodos consecutivos, siempre que no haya alcanzado la graduación ni haya sido retirado por motivos disciplinarios (MEN, 2026).

A partir de este criterio, el sistema SPADIES 3.0 calcula siete indicadores de deserción y permanencia. Entre ellos destacan la tasa de deserción anual para el corto plazo, la tasa por cohorte para el seguimiento de grupos de ingreso y la tasa promedio acumulada, que refleja la tendencia estructural a largo plazo (MEN, 2026).

Por el contrario, el conjunto de datos de la UCI aplica un criterio distinto. En este dataset, cada estudiante se clasifica como abandono, matriculado o graduado al finalizar la duración teórica de su programa (Realinho et al., 2021). Esta discrepancia conceptual significa que las tasas del conjunto de datos no son directamente comparables con las métricas de SPADIES. En consecuencia, una posterior transferencia de estos modelos al entorno colombiano requerirá de un proceso explícito de reentrenamiento y recalibración.

Las cifras más recientes muestran diferencias entre niveles de formación. En 2024, la deserción por cohorte promedio acumulada fue del 22,61 % en el nivel universitario, del 32,92 % en el técnico profesional y del 32,20 % en el tecnológico, y en los dos ciclos cortos cerca de uno de cada tres estudiantes interrumpe definitivamente sus estudios (MEN, 2026). En una serie más larga, el Laboratorio de Economía de la Educación de la Universidad Javeriana reporta que, entre 2000 y 2021, la tasa de deserción anual promedio fue del 11,0 % (Laboratorio de Economía de la Educación [LEE] de la Pontificia Universidad Javeriana, 2023). Estos valores sugieren que el abandono es un fenómeno estructural del sistema y no coyuntural.

2.2. Estado del arte

El estudio de la permanencia y el abandono en la educación superior ha experimentado una evolución conceptual y metodológica significativa. Inicialmente dominado por modelos sociológicos y cualitativos, el campo se ha transformado mediante la incorporación de la minería de datos educativos (EDM, por sus siglas en inglés) y el aprendizaje automático. Estos enfoques se orientan a la construcción de sistemas de alerta temprana capaces de procesar grandes volúmenes de información institucional.

2.2.1. Determinantes del abandono y variables de matrícula

La literatura reciente destaca que la capacidad predictiva de los modelos depende en gran medida de la naturaleza y riqueza de los datos disponibles en la etapa de ingreso. Aunque los modelos tradicionales situaban el rendimiento académico posterior como el determinante principal de la permanencia (Tinto, 1975, como se citó en Franz y Paetsch, 2023), investigaciones contemporáneas demuestran un patrón distinto. Las variables socioeconómicas y las condiciones de matrícula registradas antes del inicio de las actividades lectivas aportan una señal temprana decisiva.

Factores como la cualificación académica de los padres, el estado civil, la modalidad de asistencia (diurna o nocturna) y el historial académico previo influyen directamente en la vulnerabilidad del estudiante (Hadjar et al., 2023). En esta línea, Realinho et al. (2021) consolidaron un conjunto de datos multidimensional que formaliza estas variables al momento de la matrícula, junto con el desempeño en los dos primeros semestres. Este aporte

ofrece una base estandarizada para evaluar la capacidad de anticipación de los algoritmos sin depender exclusivamente del rendimiento acumulado tardío.

2.2.2. Evolución de las técnicas de aprendizaje automático

En el ámbito metodológico, la predicción de la deserción ha transitado desde modelos estadísticos lineales y árboles de decisión individuales hacia algoritmos de ensamble más complejos. La revisión sistemática de Silva y Roman (2021) muestra que los árboles de decisión han sido la técnica más utilizada, seguidos de los métodos bayesianos y la regresión logística, mientras que los modelos de ensamble aparecen solo en el 28,5 % de los estudios. Frente a este panorama, trabajos posteriores sobre el conjunto de datos de Realinho et al. (2021) indican que los métodos de boosting, como XGBoost, LightGBM y CatBoost, ofrecen un rendimiento superior (Villar y de Andrade, 2024). Esto se atribuye a su capacidad para capturar interacciones no lineales complejas entre variables heterogéneas.

Trabajos recientes en entornos universitarios respaldan que las arquitecturas basadas en potenciar árboles (boosting) superan de forma consistente a los clasificadores individuales en desempeño predictivo. Este rendimiento destaca especialmente cuando se procesan datos tabulares mixtos que combinan indicadores continuos y categóricos (Villar y de Andrade, 2024; Nguyen et al., 2024). Específicamente, investigaciones que evalúan modelos de ensamble sobre el conjunto de datos de la UCI han evidenciado que algoritmos como LightGBM y CatBoost superan a clasificadores tradicionales como los árboles de decisión, las SVM y Random Forest (Villar y de Andrade, 2024; Nguyen et al., 2024).

2.2.3. Desbalance de clases, métricas de evaluación y escenarios temporales

Un desafío recurrente en la modelación del abandono es el desbalance de clases, donde la proporción de estudiantes que abandonan es sustancialmente menor que la de aquellos que permanecen o se gradúan. He y Garcia (2009) advierten que el uso acrítico de la exactitud (accuracy) en conjuntos desbalanceados produce modelos sesgados hacia la clase mayoritaria. Esto genera una falsa sensación de alto desempeño mientras se ignora a la población en riesgo.

Para mitigar esta limitación, la investigación orientada a la toma de decisiones prioriza métricas centradas en la clase minoritaria, específicamente la sensibilidad (recall) y el F1-score, complementadas con técnicas de balanceo o ajuste de umbrales de decisión (Chawla

et al., 2002; Thammasiri et al., 2014; Silva y Roman, 2021). Por ejemplo, en el ámbito de la retención universitaria, estudios como el de Thammasiri et al. (2014) muestran que la exactitud global puede ser engañosa y que las técnicas de balanceo mejoran la detección de la clase minoritaria, un hallazgo coherente con la prioridad que la revisión de Silva y Roman (2021) otorga a la sensibilidad en los sistemas de alerta temprana. El costo institucional y social de no identificar a un estudiante en riesgo de deserción (falso negativo) supera sustancialmente al costo de ofrecer un acompañamiento preventivo a un estudiante que no lo requería (falso positivo).

Asimismo, la dimensión temporal resulta técnica y operativamente decisiva. Evaluar el desempeño predictivo en múltiples momentos, desde la matrícula (E_1) hasta la finalización de los primeros semestres (E_2y E_3), lo cual permite determinar el trade-off entre la oportunidad de la alerta y la precisión de la prueba, un aspecto central para la efectividad de las intervenciones institucionales (Chow, 2024). Como demuestra Chow (2024), que el desempeño de un Random Forest mejora al incorporar información académica: F1 de 0,68 con datos de admisión, 0,80 al cierre del primer semestre y 0,85 al cierre del segundo. Entonces, intervenir tempranamente en E_1 maximiza la ventana de oportunidad pedagógica antes de que el estudiante se desvincule, aunque con mayor incertidumbre; mientras que evaluar en E_2o E_3incrementa la precisión a costa de reducir el tiempo de respuesta institucional. Analizar formalmente este balance permite a las universidades optimizar la asignación de recursos de acompañamiento según el nivel de certeza y el momento de la trayectoria académica.

2.2.4. Equidad algorítmica e interpretabilidad en la educación

Con la adopción creciente de modelos predictivos en la gestión académica, la literatura exige que la precisión técnica esté acompañada de garantías éticas. Karimi-Haghighi et al. (2021) demostraron la necesidad de auditar los clasificadores de deserción bajo criterios de equidad algorítmica (algorithmic fairness). Su trabajo verifica que la tasa de falsos negativos no perjudique de forma desproporcionada a subgrupos definidos por variables demográficas o socioeconómicas.

Complementariamente, el uso de técnicas de Inteligencia Artificial Explicable (XAI), como los valores SHAP (SHapley Additive exPlanations), ha cobrado relevancia para abrir la "caja negra" de los modelos de ensamble (Lundberg y Lee, 2017; Nagy y Molontay, 2024; Villar y de

Andrade, 2024). En el ámbito educativo, autores como Nagy y Molontay (2024) y Villar y de Andrade (2024) han demostrado que la integración de SHAP permite a los gestores educativos e ingenieros de datos puedan identificar de manera cuantitativa y comprensible cuáles características contribuyen de forma positiva o negativa al riesgo individual de abandono.

Este nivel de interpretabilidad asegura que la predicción no opere como un juicio automatizado arbitrario, sino como un insumo transparente, auditable y fundamentado para el acompañamiento pedagógico e institucional (Nagy y Molontay, 2024)

2.3.Conclusiones

Para abordar estas limitaciones, el presente trabajo propone un piloto experimental que evalúa modelos de ensamble sobre el conjunto de datos de Realinho et al. (2021), estructurando la detección en tres escenarios temporales (E_1, E_2, E_3). La contribución se centra en determinar estadísticamente el valor añadido de la anticipación algorítmica frente al caso base, priorizando la sensibilidad en la detección, auditando el comportamiento del modelo en materia de equidad por subgrupos socioeconómicos y garantizando la trazabilidad y reproducibilidad del pipeline de datos.

Referencias bibliográficas

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). *SMOTE: Synthetic Minority Over-sampling Technique.* Journal of Artificial Intelligence Research, 16, 321–357. https://doi.org/10.1613/jair.953

Chacón Sánchez, N. V., Casas Mateus, D. E., y Alvarado Nieto, L. D. (2020). Behavior of employability indicators in university graduates. *Ingeniería Solidaria, 16*(2). https://doi.org/10.16925/2357-6014.2020.02.03

Chow, W. (2024). Improving Early Dropout Detection in Undergraduate Students: Exploring Key Predictors through SHAP Values. The Engineer and the World. https://findanexpert.unimelb.edu.au/scholarlywork/1957055-improving-early-dropout-detection-in-undergraduate-students--exploring-key-predictors-through-shap-values

Franz, S., y Paetsch, J. (2023). Academic and social integration and their relation to dropping out of teacher education: A comparison to other study programs. *Frontiers in Education, 8*, Artículo 1179264. https://doi.org/10.3389/feduc.2023.1179264

Hadjar, A., Haas, C., y Gewinner, I. (2023). Refining the Spady–Tinto approach: The roles of individual characteristics and institutional support in students' higher education dropout intentions in Luxembourg. *European Journal of Higher Education, 13*(4), 409-428. https://doi.org/10.1080/21568235.2022.2056494

He, H., y Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering, 21*(9), 1263-1284. https://doi.org/10.1109/TKDE.2008.239

Karimi-Haghighi, M., Castillo, C., Hernández-Leo, D., y Moreno Oliver, V. (2021). *Predicting early dropout: Calibration and algorithmic fairness considerations*. arXiv. https://arxiv.org/abs/2103.09068

Laboratorio de Economía de la Educación de la Pontificia Universidad Javeriana. (2023). Informe No. 74 Deserción en la educación superior en Colombia. Disponible en https://lee.javeriana.edu.co/publicaciones-y-documentos

Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30, 4765–4774. https://doi.org/10.48550/arXiv.1705.07874

Nagy, M., y Molontay, R. (2024). Interpretable dropout prediction: Towards XAI-based personalized intervention. International Journal of Artificial Intelligence in Education, 34(2), 274–300. https://doi.org/10.1007/s40593-023-00331-8

Nguyen, H. T., Le, P., Nguyen, T. T. T., y Su, A. K. (2024). A multivariate analysis of the early dropout using classical machine learning and local interpretable model-agnostic explanations. CTU Journal of Innovation and Sustainable Development, 16(Special Issue: ISDS), 98–106. https://doi.org/10.22144/ctujoisd.2024.327

Ministerio de Educación Nacional. (2026, 22 de septiembre). *Estadísticas de deserción y permanencia en educación superior: SPADIES 3.0 – Indicadores 2024*. Sistema para la Prevención y Análisis de la Deserción en las Instituciones de Educación Superior. https://www.mineducacion.gov.co/sistemasinfo/spadies/secciones/Estadisticas-de-desercion/

OECD. (2025). *Education at a glance 2025: OECD indicators*. OECD Publishing. https://doi.org/10.1787/1c0d9c79-en

Realinho, V., Vieira Martins, M., Machado, J., y Baptista, L. (2021). *Predict students' dropout and academic success* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89

Realinho, V., Machado, J., Baptista, L., y Martins, M. V. (2022). Predicting student dropout and academic success. Data, 7(11), 146. https://doi.org/10.3390/data7110146

Silva, J. J. da, y Roman, N. T. (2021). Predicting dropout in higher education: A systematic review. En *Anais do XXXII Simpósio Brasileiro de Informática na Educação* (pp. 1107-1117). Sociedade Brasileira de Computação. https://doi.org/10.5753/sbie.2021.217437

Thammasiri, D., Delen, D., Meesad, P., y Kasap, N. (2014). A critical assessment of imbalanced class distribution problem: The case of predicting freshmen student attrition. Expert Systems with Applications, 41(2), 321–330. https://doi.org/10.1016/j.eswa.2013.07.046

Villar, A., y de Andrade, C. R. V. (2024). Supervised machine learning algorithms for predicting student dropout and academic success: A comparative study. Discover Artificial Intelligence, 4, Artículo 2. https://doi.org/10.1007/s44163-023-00079-z